

Факультет компьютерных наук Департамент программной инженерии

КОМПОНЕНТ-РАСШИРЕНИЕ РСУБД SQLITE ДЛЯ ИНДЕКСИРОВАНИЯ ДАННЫХ МОДИФИКАЦИЯМИ В-ДЕРЕВЬЕВ

Антон Ригин

Научный руководитель: Шершаков С.А., ст. преп. ДПИ ФКН, н.с. НУЛ ПОИС ФКН



ПРЕДМЕТНАЯ ОБЛАСТЬ

- Сильно ветвящиеся деревья: В-деревья, В+-деревья, В+-деревья и В+-деревья
- Эмпирическая оценка сложности основных операций и объёма занимаемой памяти
- Индексы в СУБД
- SQLite встраиваемая реляционная СУБД
- Использование сильно ветвящихся деревьев в качестве индекса в SQLite





Пример В-дерева порядка 6, высоты 2

Узел (листовой)



ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- Сильно ветвящееся дерево (структура данных)
 такое дерево, которое содержит в одном узле более одного элемента с ключом и более одной связи с дочерними узлами.
- В-дерево Сильно ветвящееся дерево. В-дерево построено так, что если некоторый узел содержит k ключей, то у данного узла k+1 потомков, и для любого i, такого, что $1 \le i \le k+1$, верно, что все ключи в i-м потомке данного узла не меньше, чем i-й ключ данного узла, и не больше, чем i+1-й ключ данного узла [6].
- Порядок В-дерева такое число t, что для любого некорневого узла дерева верно неравенство: $t-1 \le k \le 2t-1$, где k число ключей в узле. Корневой узел для непустого В-дерева содержит $1 \le k \le 2t-1$ ключей, для пустого В-дерева 0 ключей [6].
- В-дерево является **сбалансированным деревом**, поэтому его высота будет равна $O(log_t n)$, где n число ключей в дереве [6].

[6] Т. Кормен, Ч. Лейзерсон, Р. Ривест, К. Штайн. Алгоритмы: построение и анализ. 3-е изд.



ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- В*-дерево модификация В-дерева. В В+-дереве настоящие ключи хранятся лишь в листьях дерева, а во внутренних узлах хранятся лишь ключи-маршрутизаторы, необходимые для поиска по дереву. Листья в В+-дереве содержат $t \le n \le 2t$ ключей, где t порядок дерева, ограничения для внутренних узлов такие же, как и в В-дереве. Деление листьев происходит поровну на две части, крайний ключ из левой половины делимого узла копируется в родительскую вершину в качестве ключа-маршрутизатора аналогично перемещению медианы для обычного деления, деление внутренних узлов происходит так же, как и в В-дереве [3].
- **В***-дерево модификация В-дерева. Каждый узел заполняется не менее, чем на 2/3, а не 1/2. По этой причине, вместо традиционного разбиения узла, происходит

- перераспределение ключей между соседними узламипотомками, либо, если нет незаполненных соседей, то узел разбивается на три (а не на две) части [1] [5].
- В*+-дерево модификация В-дерева, разработанная в рамках выполнения курсовой работы за 3 курс. Представляет собой совмещение В+-дерева и В*-дерева: модификация заполненных вершин при вставке выполняется как в В*-дереве (переливание либо разбиение на три части), при этом, как в В+-дереве, реальные данные хранятся только в листьях, в остальных вершинах находятся лишь ключимаршрутизаторы.
 - [1] https://xlinux.nist.gov/dads/HTML/bstartree.html
 - [3] Kerttu Pollari-Malmi. B+-trees: https://www.cs.helsinki.fi/u/mluukkai/tirak2010/B-tree.pdf
 - [5] Д. Кнут. Искусство программирования. Том 3. 2-е изд.



ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- СУБД система управления базами данных
- РСУБД реляционная СУБД
- SQLite РСУБД с открытым исходным кодом (написана на языке С)
- **Расширение SQLite** библиотека динамического подключения, расширяющая функционал РСУБД SQLite и предоставляющая новые функции [4]



АКТУАЛЬНОСТЬ

- В настоящее время растут объёмы обрабатываемых данных
- Необходимо разрабатывать новые эффективные подходы к индексации данных в СУБД
- СУБД SQLite содержит небольшое число способов индексирования данных актуально добавление новых



СУЩЕСТВУЮЩИЕ РЕШЕНИЯ

- В-дерево является способом индексации по умолчанию в SQLite
- Существует ряд расширений для SQLite, добавляющих, например, индексирование при помощи R-дерева
- Расширений с В+-деревом, В*-деревом и В*+-деревом не обнаружено



ЦЕЛЬ И ЗАДАЧИ РАБОТЫ

• Цель работы

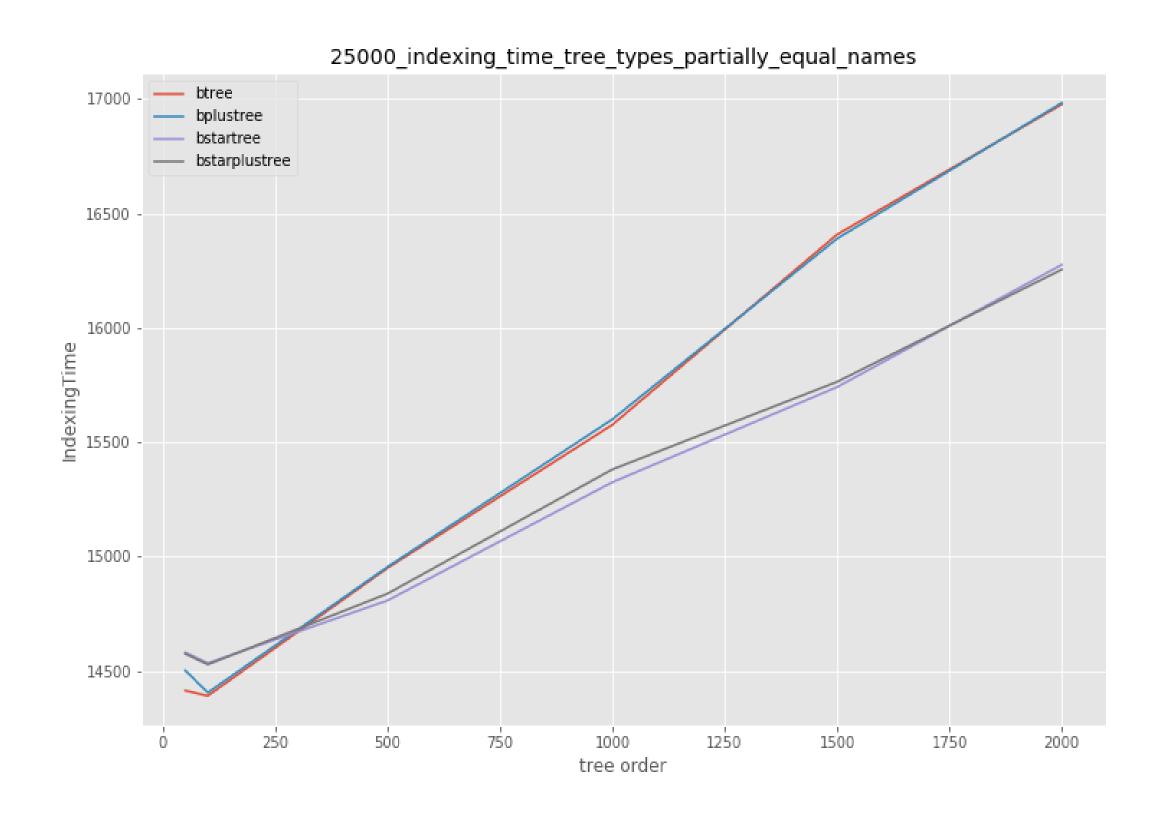
✓ Разработать расширение для SQLite, позволяющее использовать в качестве индекса в данной СУБД модификации В-дерева: В+-дерево, В*-дерево и В*+- дерево

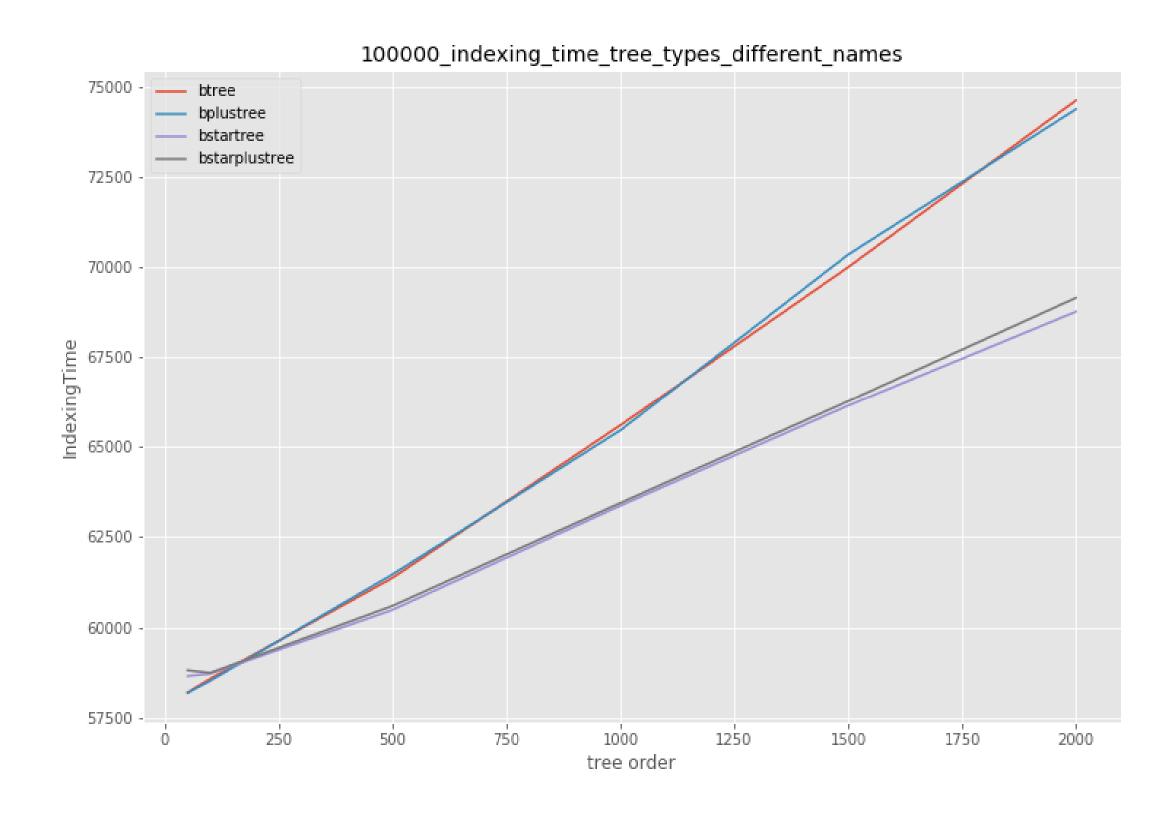
• Задачи работы

- ✓ Подключить имеющуюся С++-библиотеку к SQLite в качестве расширения
- ✓ Разработать алгоритм выбора наиболее подходящей структуры данных (В-дерева либо одной из его модификаций) для индексирования таблицы
- ✓ Написать расширение для SQLite-менеджера для визуализации В-деревьев и их модификаций, а также рассчитанных для них метрик



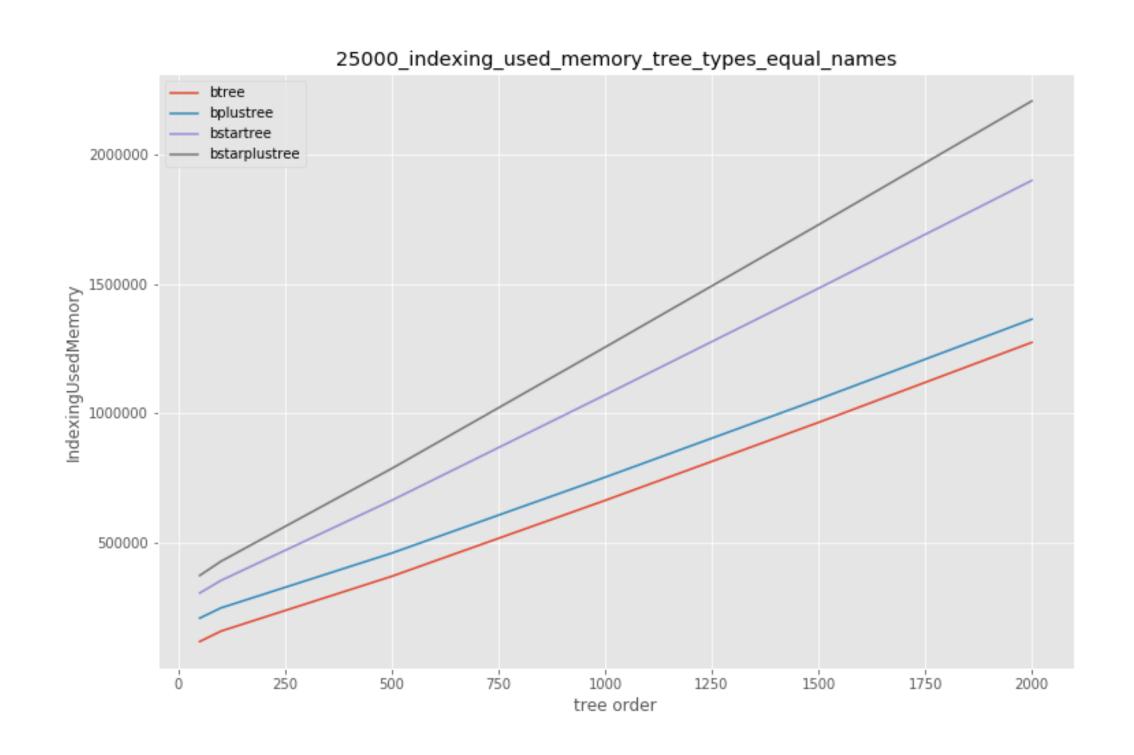
Индексация – время

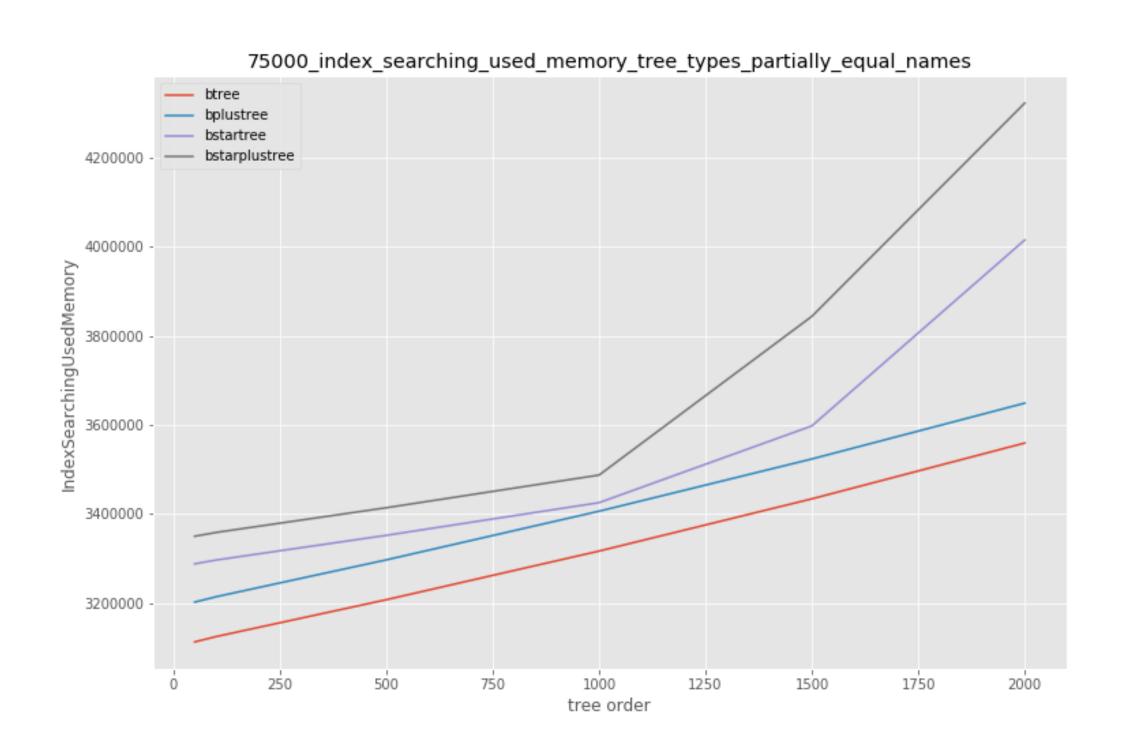






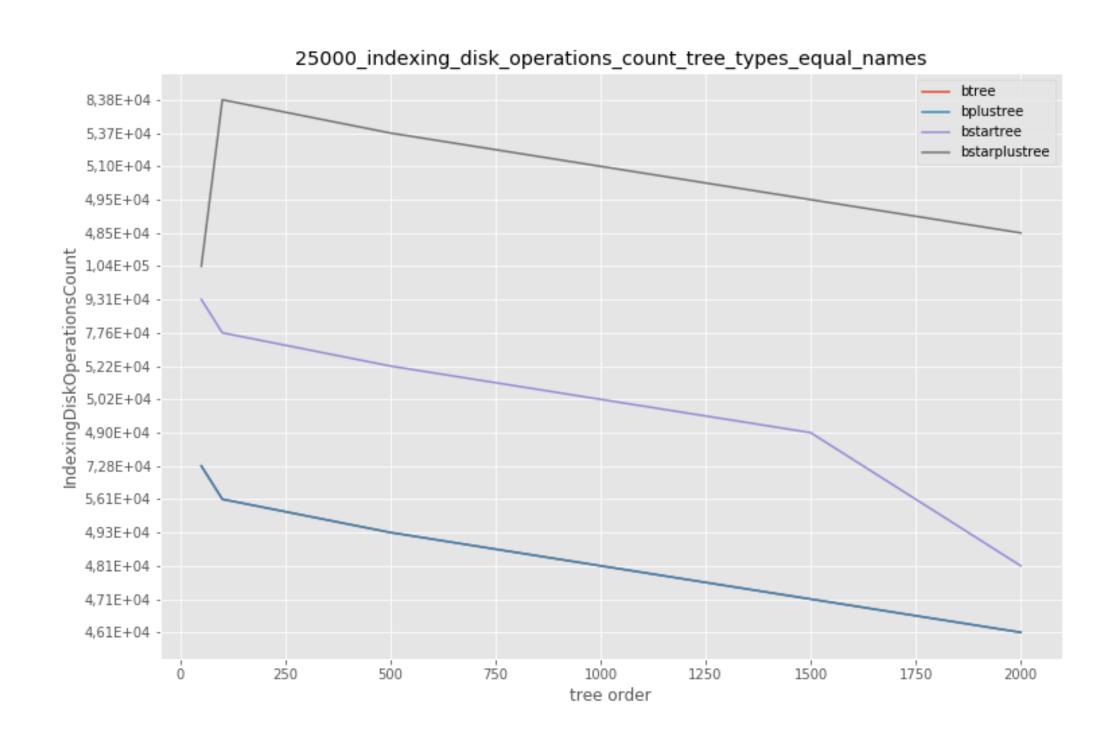
Индексация – память

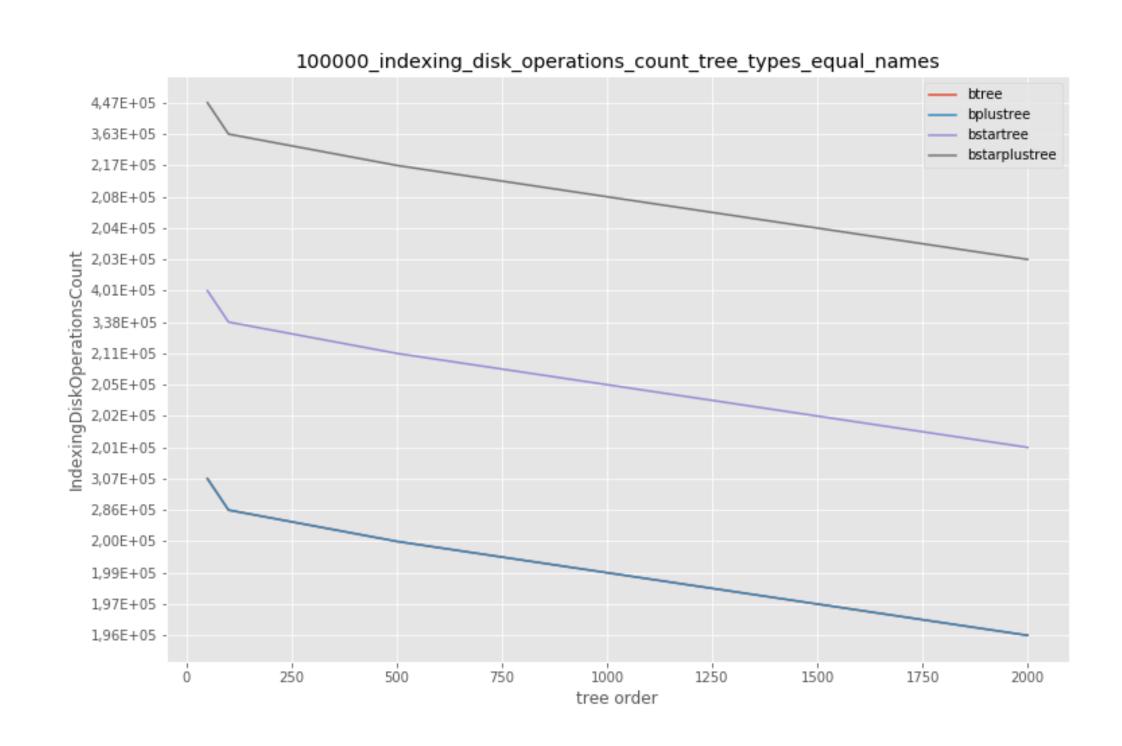






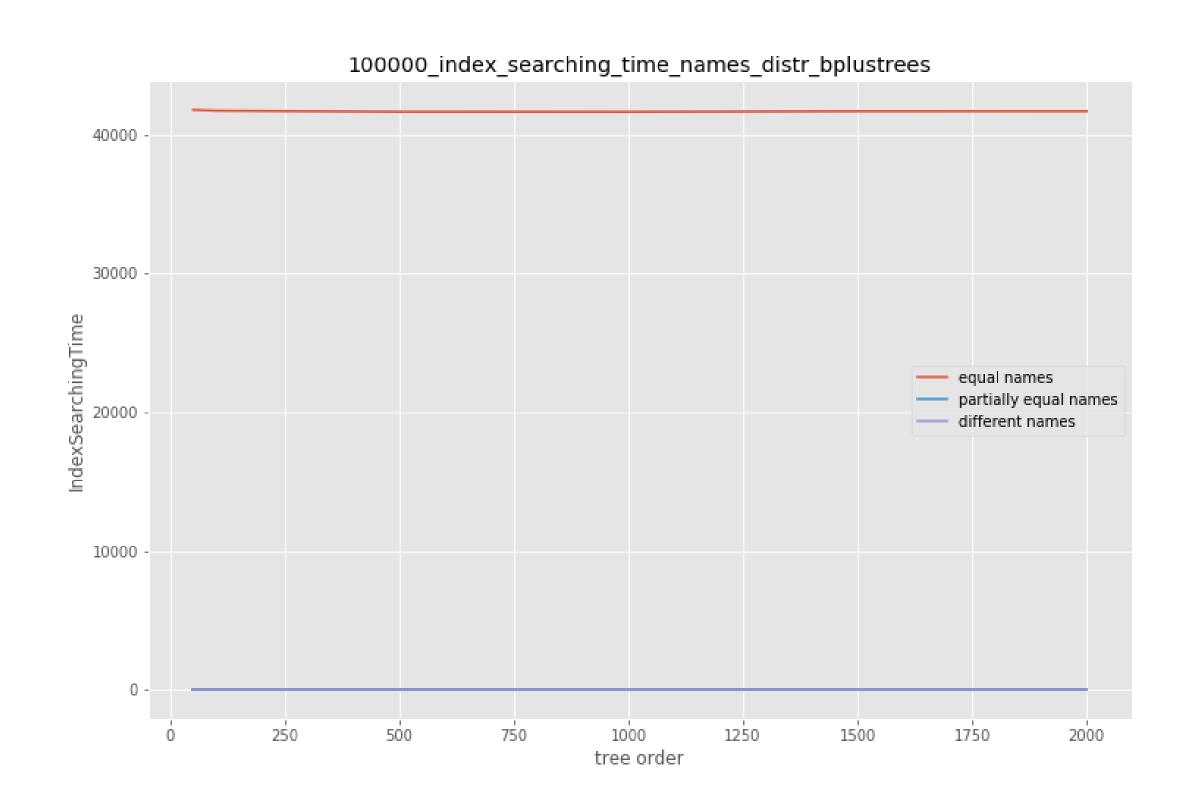
Индексация – дисковые операции

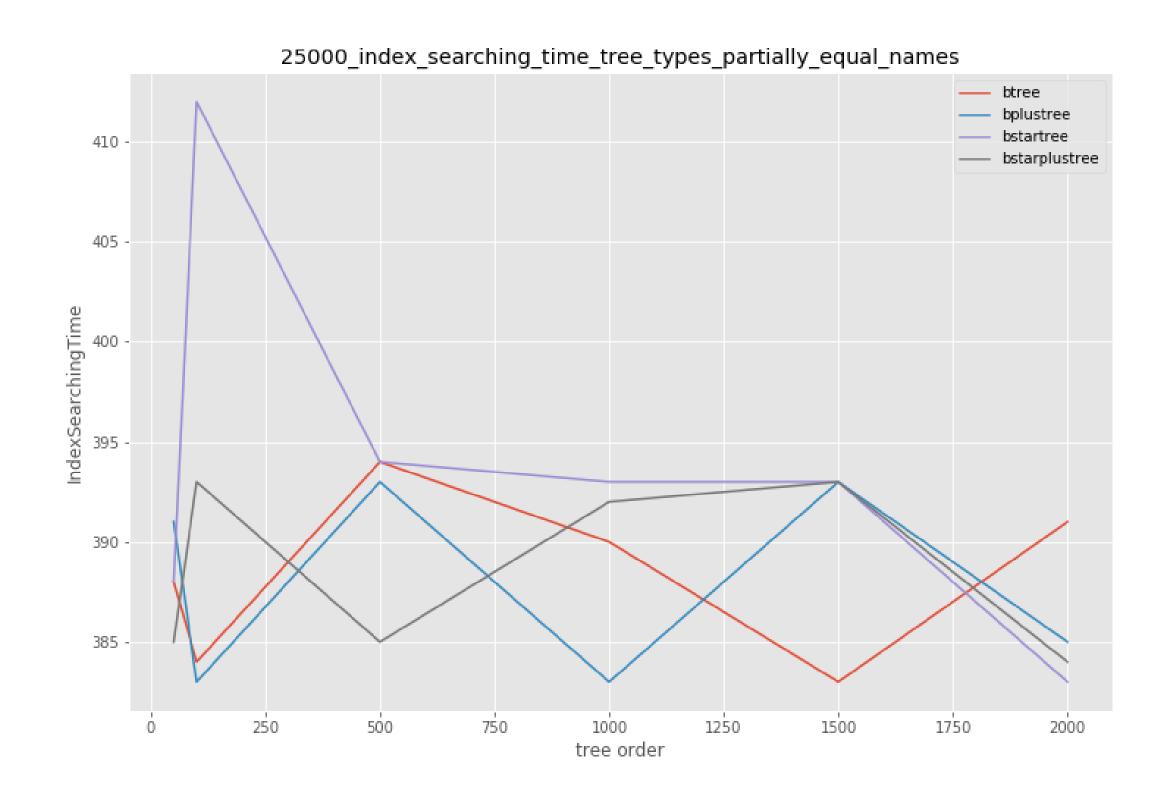






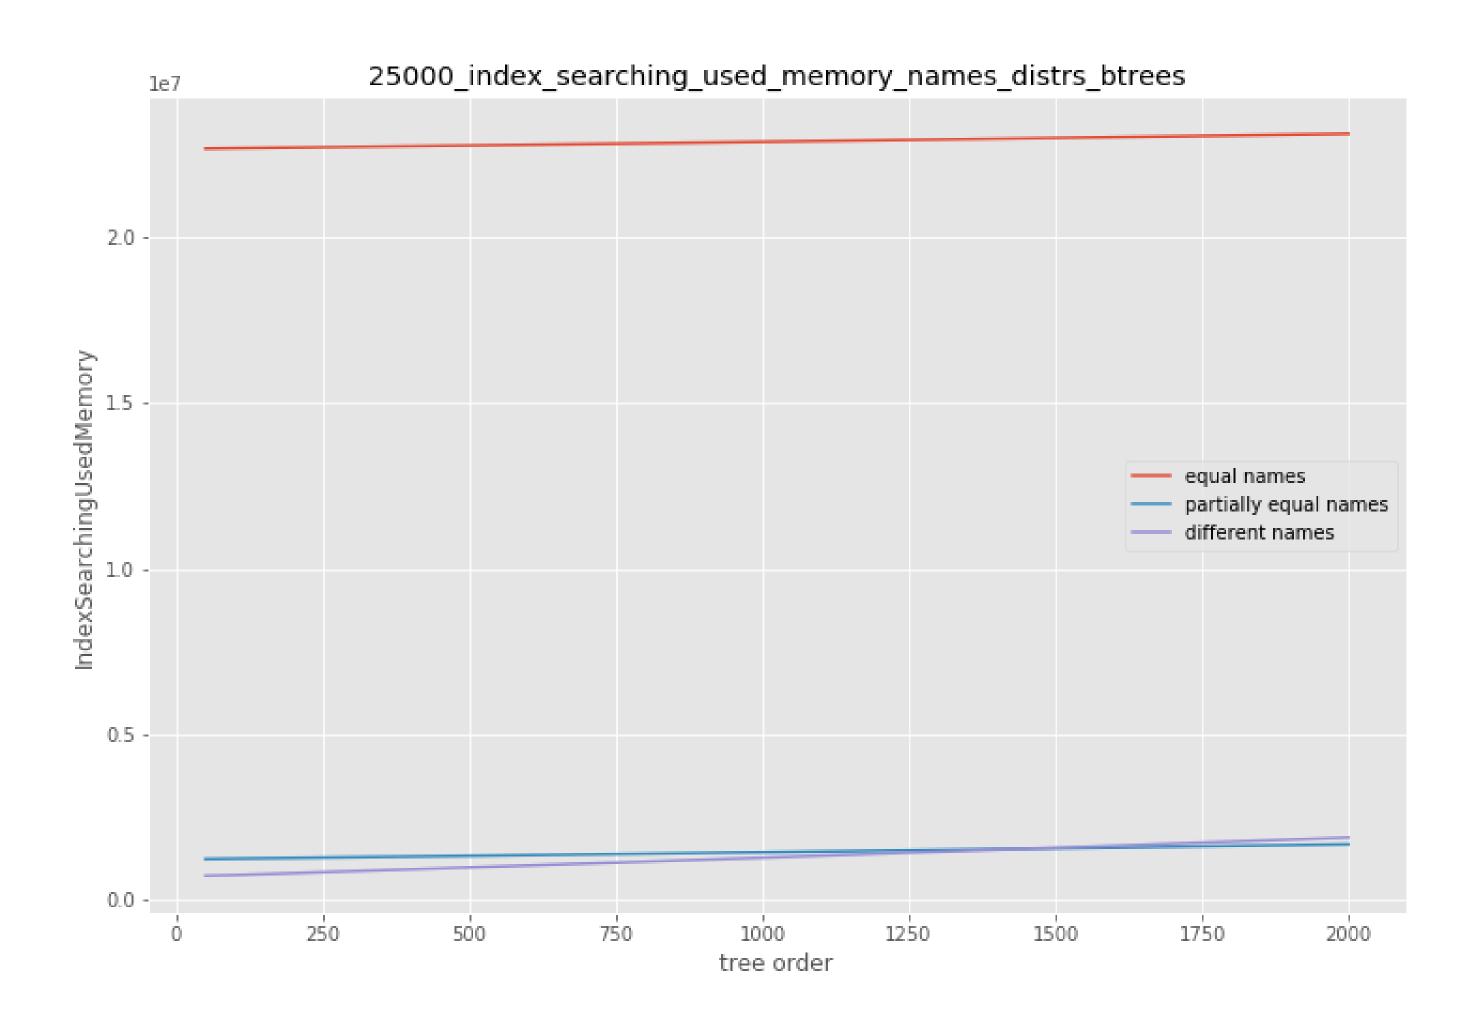
Поиск по индексу – время





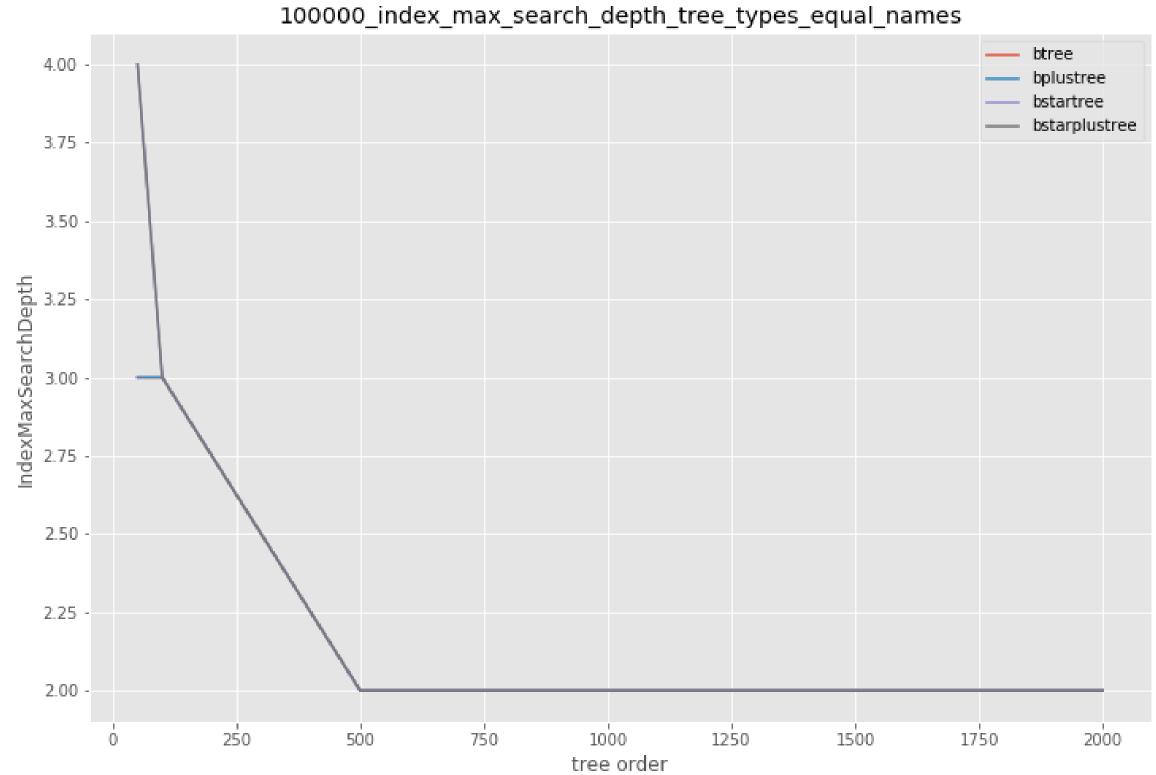


Поиск по индексу – память



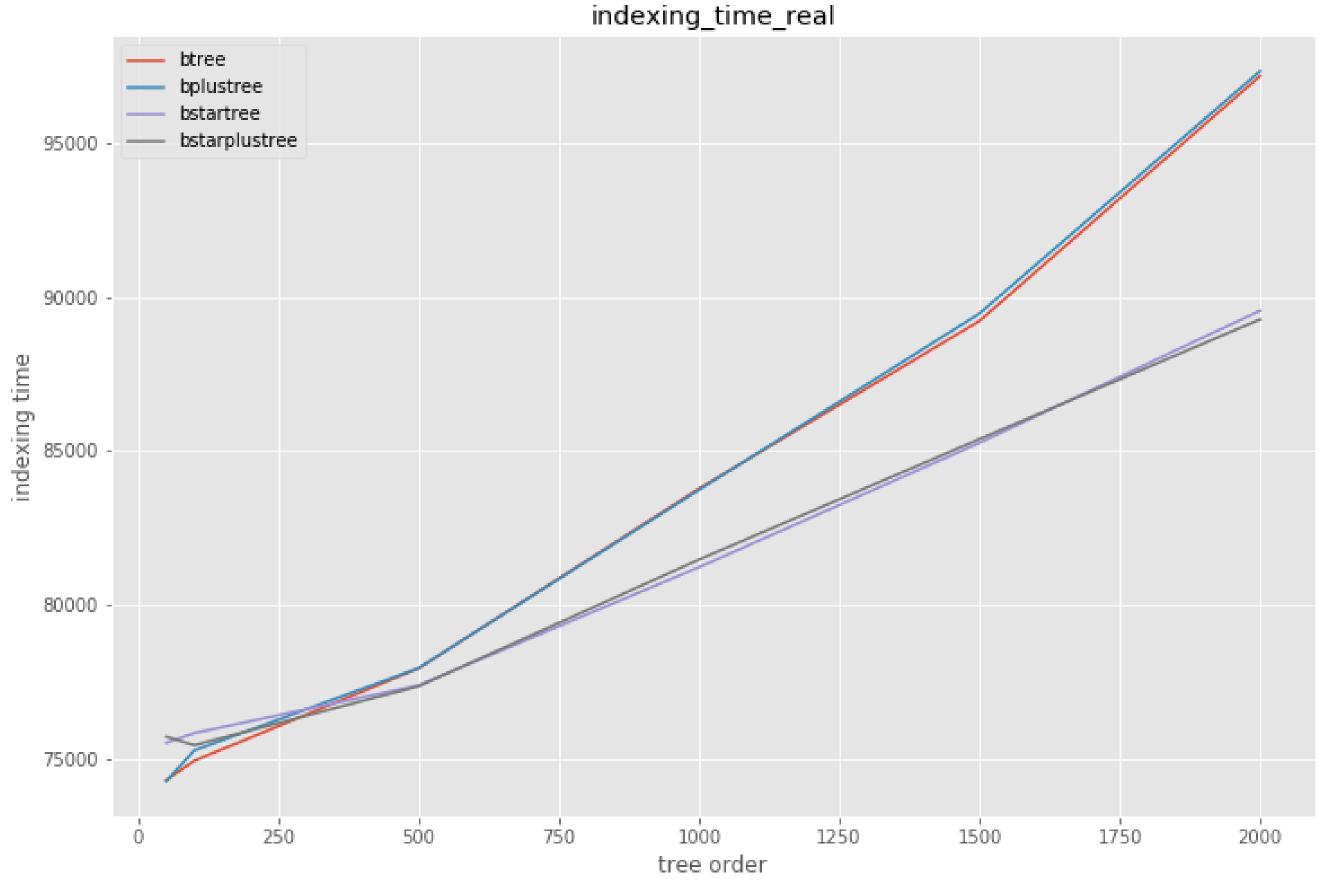


Поиск по индексу – определение высоты дерева



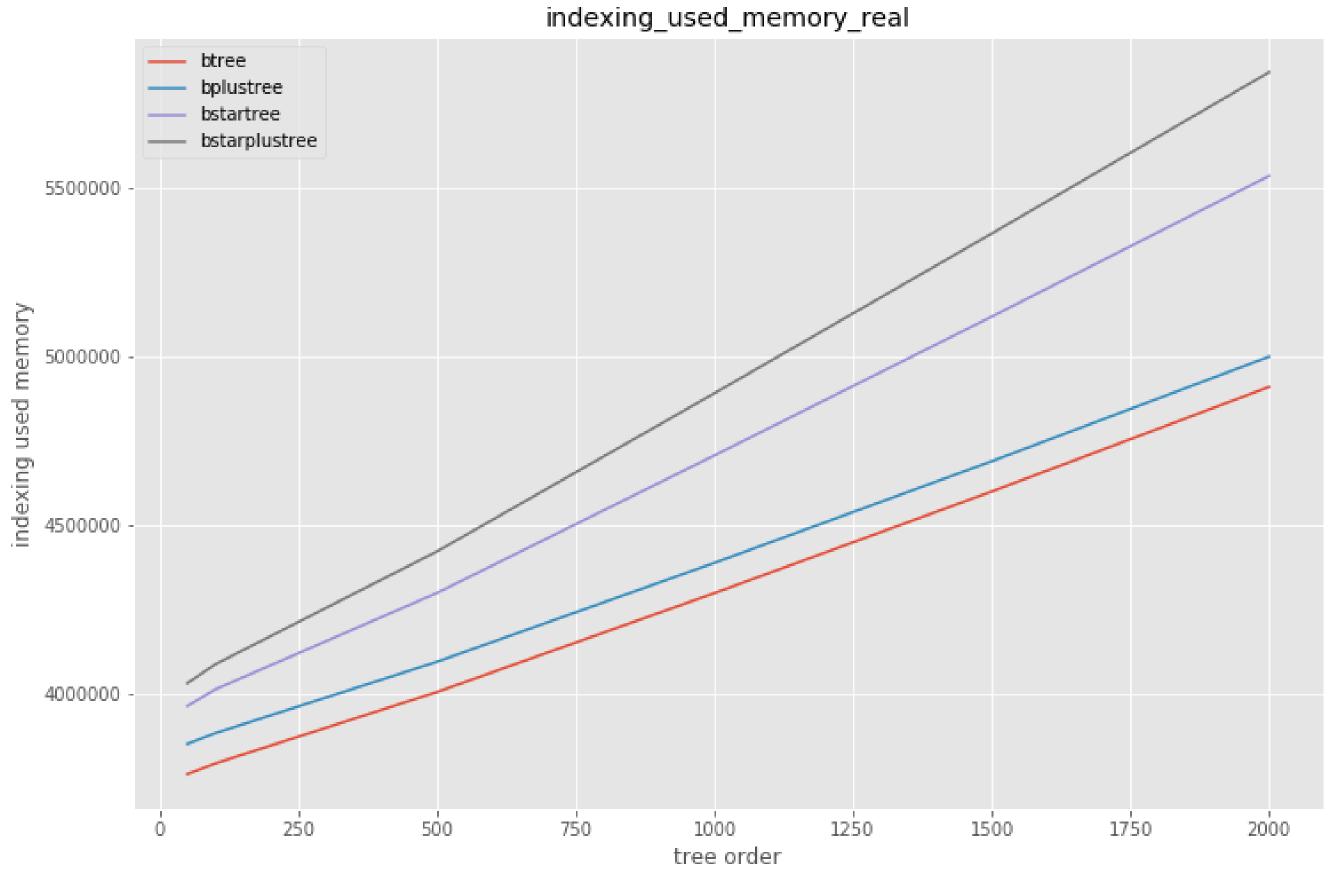


Индексация (реальные данные) – время



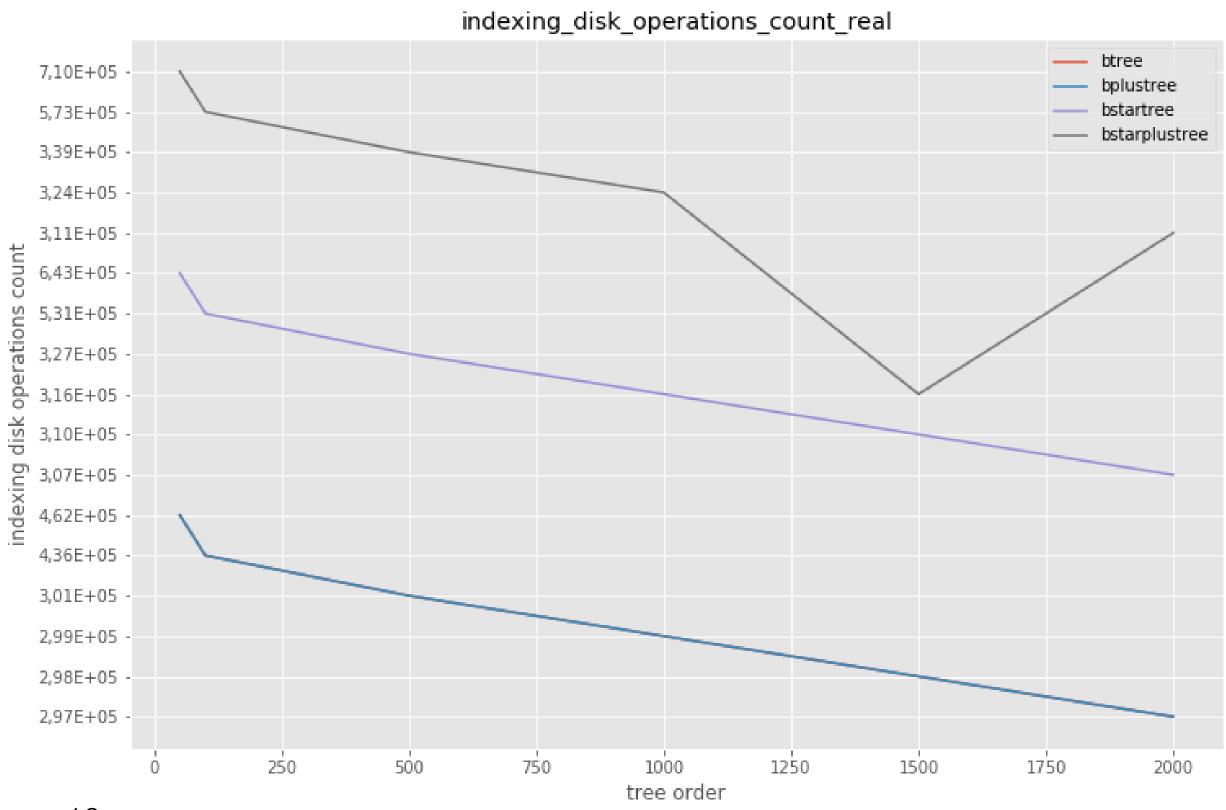


Индексация (реальные данные) – память



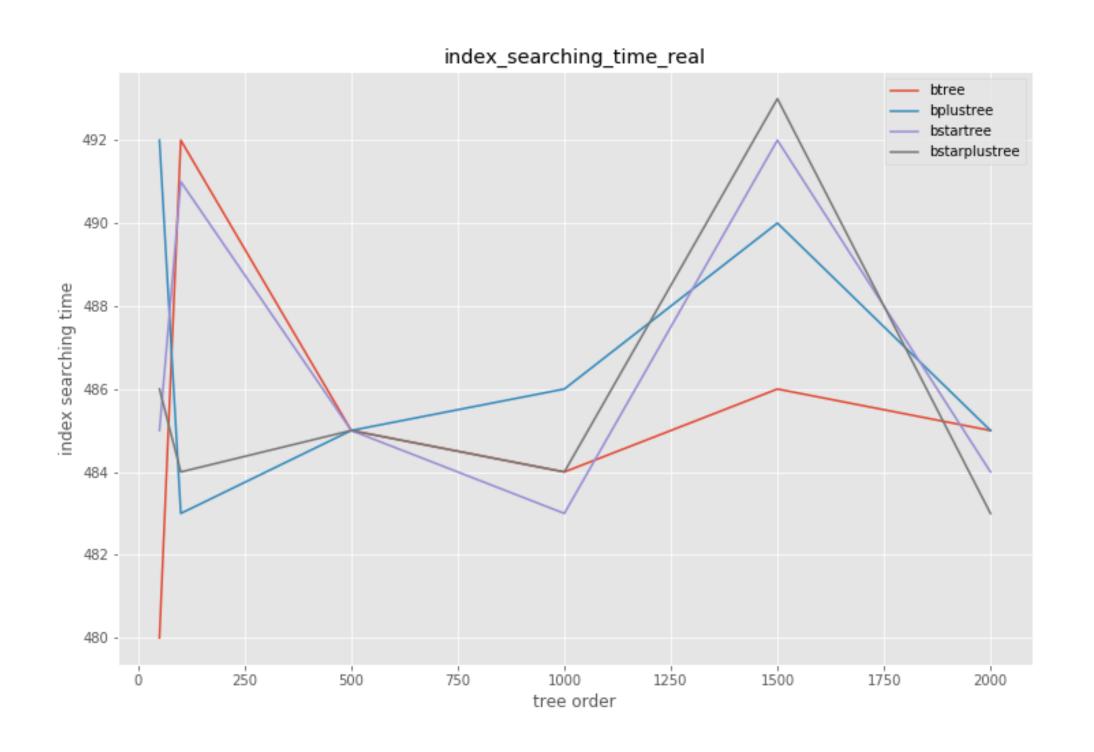


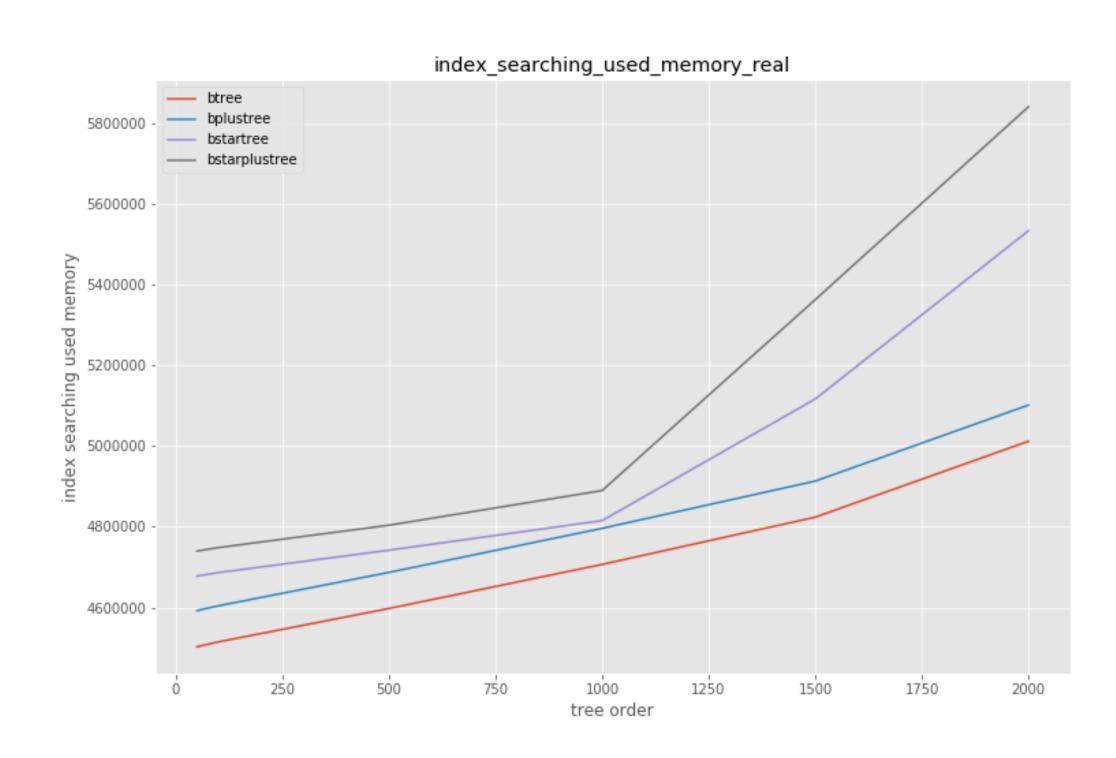
Индексация (реальные данные) – дисковые операции





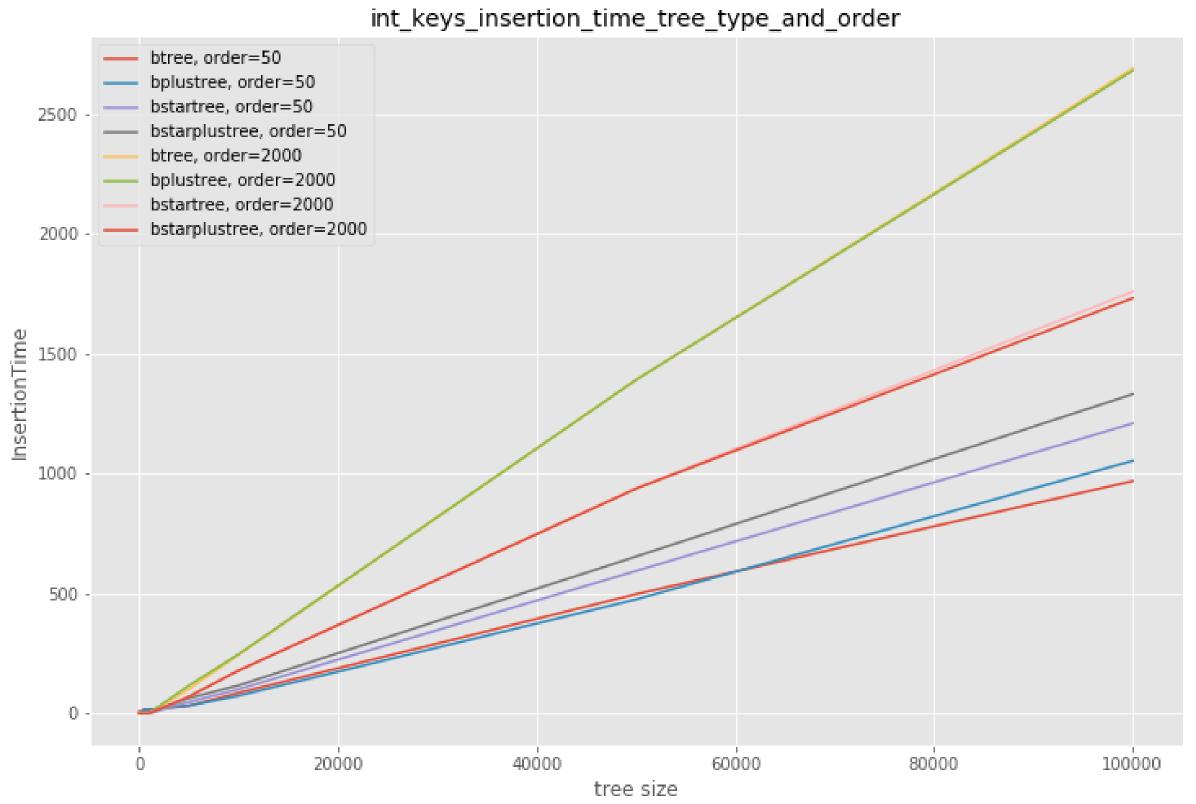
Поиск по индексу (реальные данные) – время и память





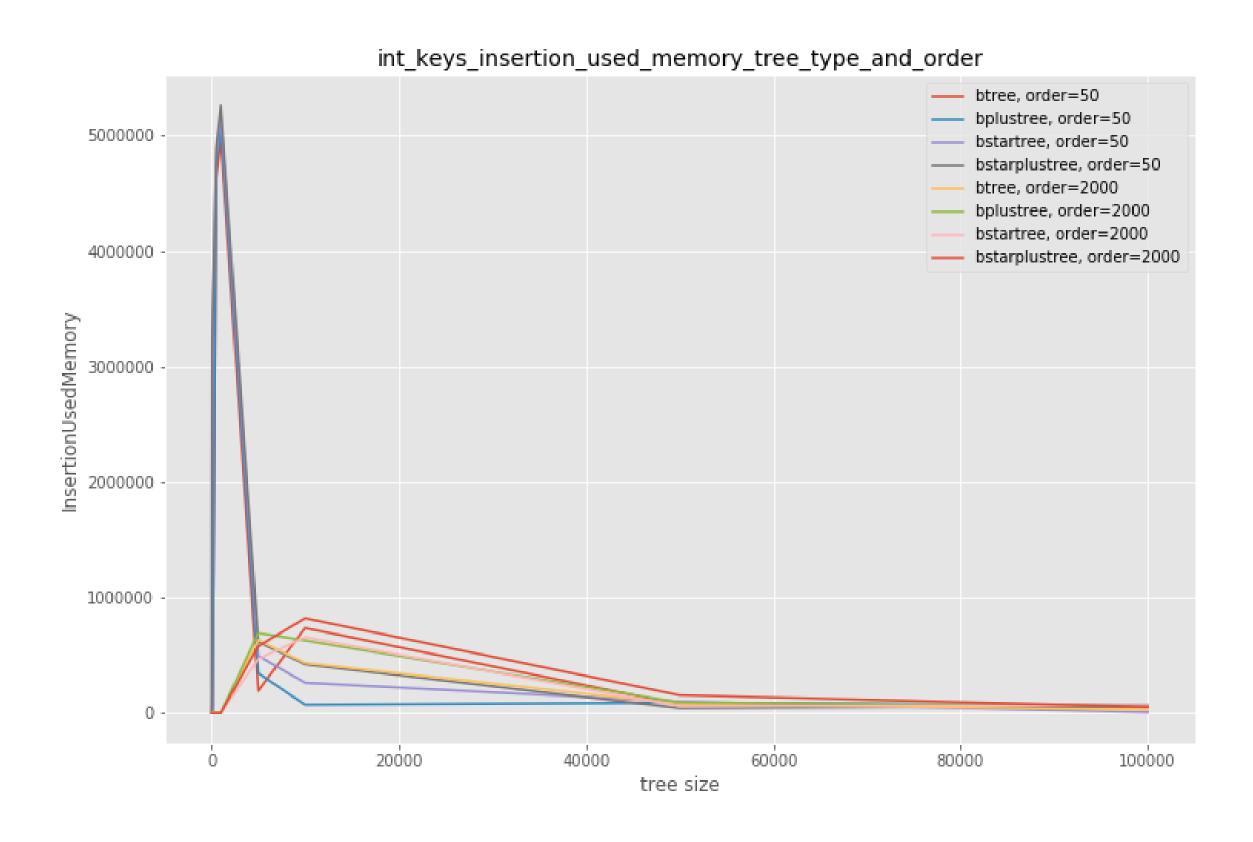


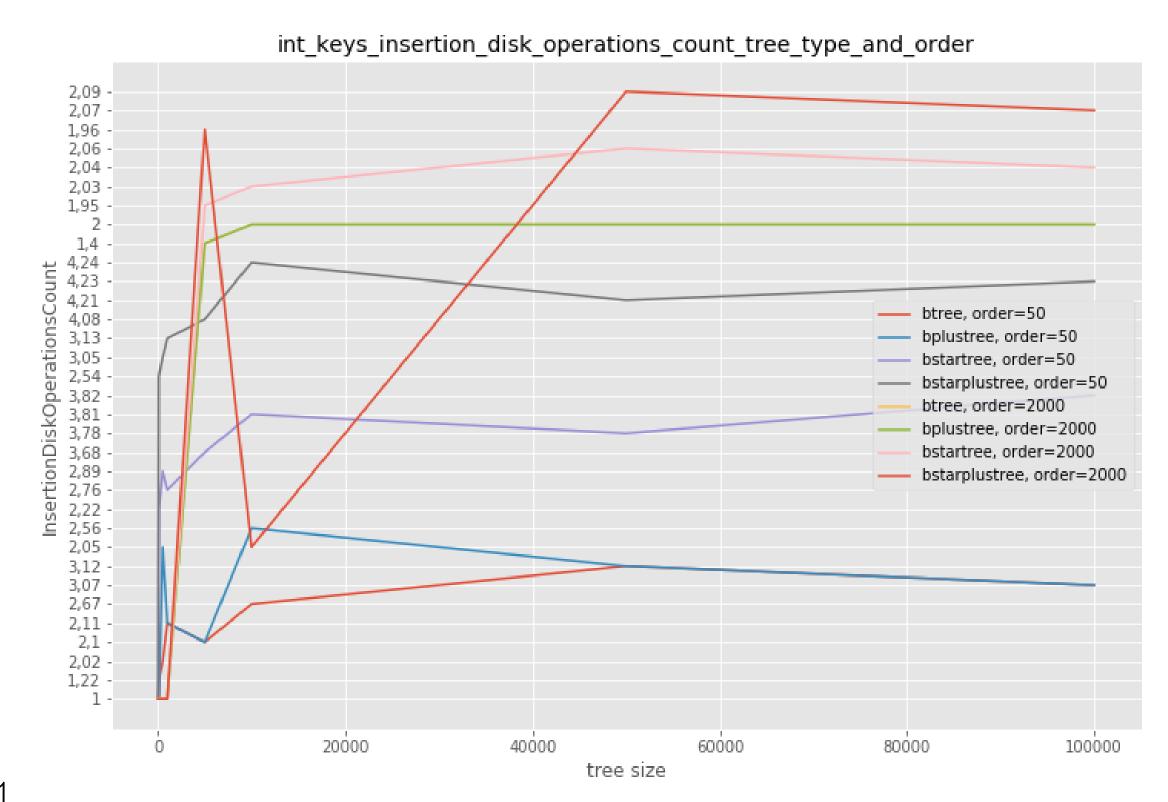
Вставка в дерево (целочисленные ключи) – время





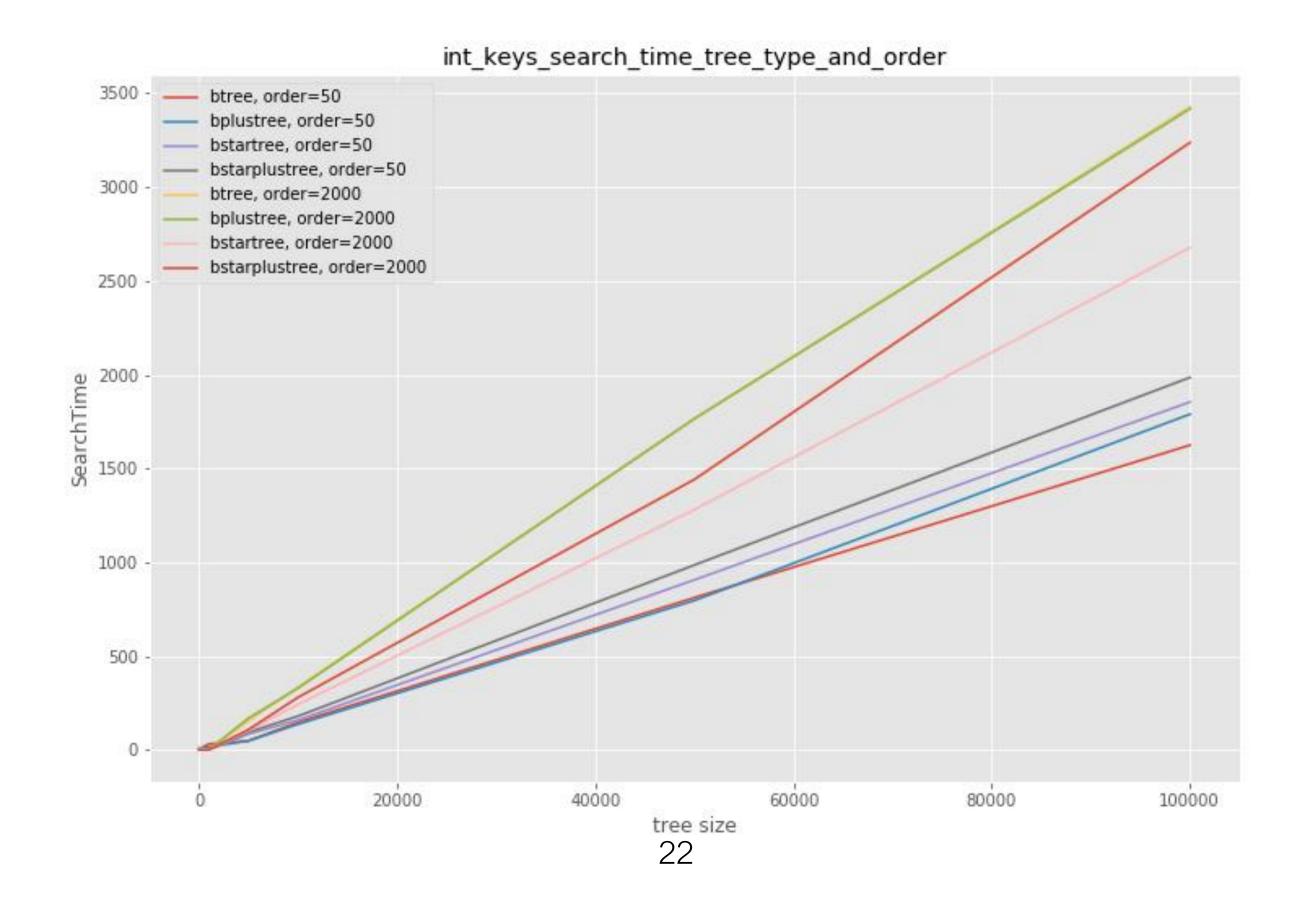
Вставка в дерево (целочисленные ключи) – память и дисковые операции





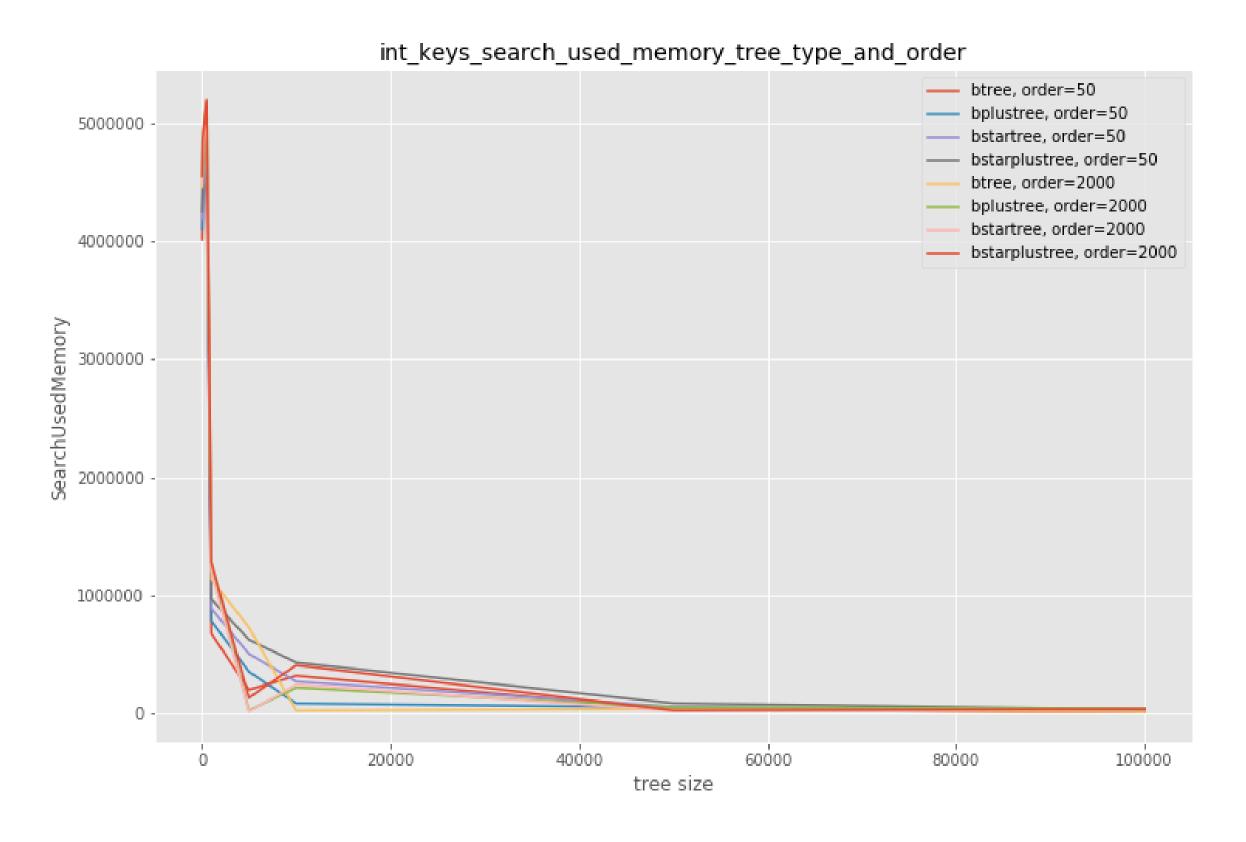


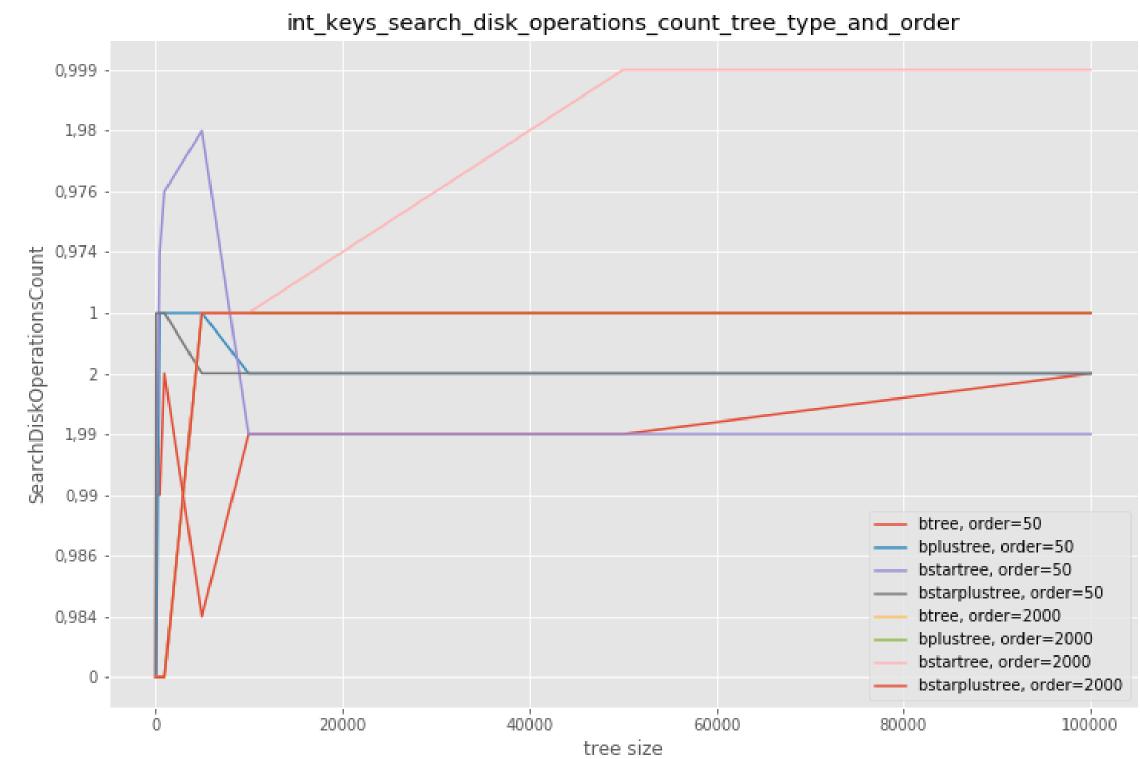
Поиск в дереве (целочисленные ключи) – время





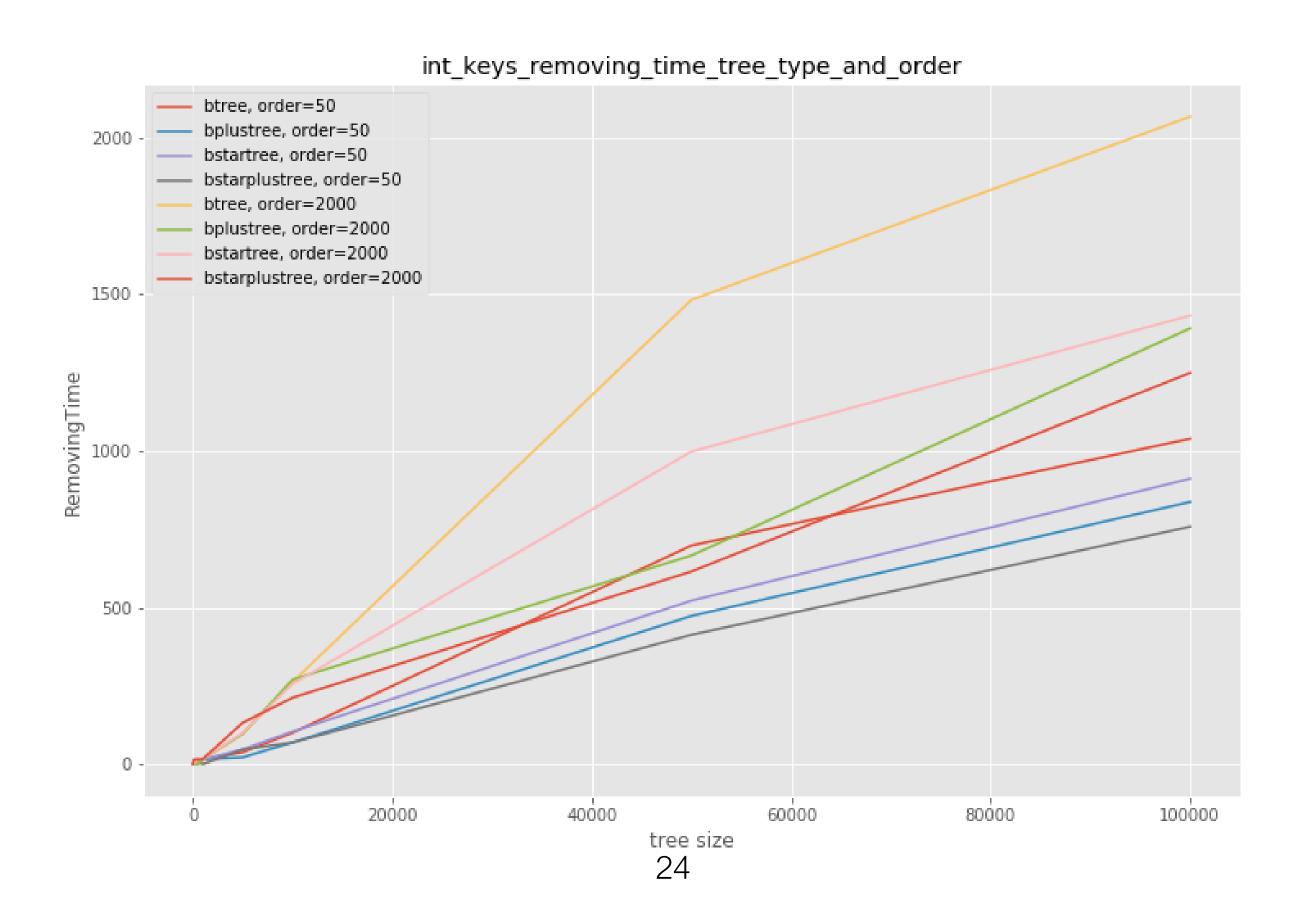
Поиск в дереве (целочисленные ключи) – память и дисковые операции





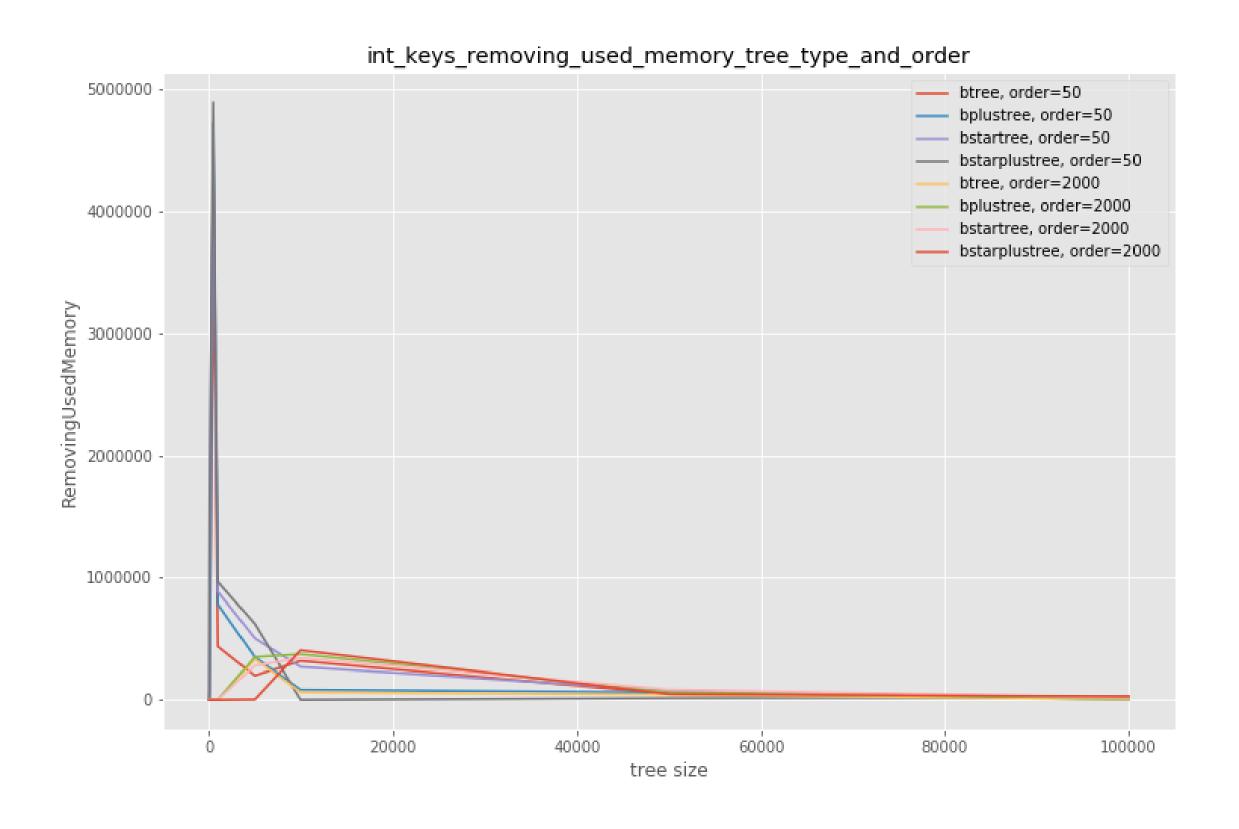


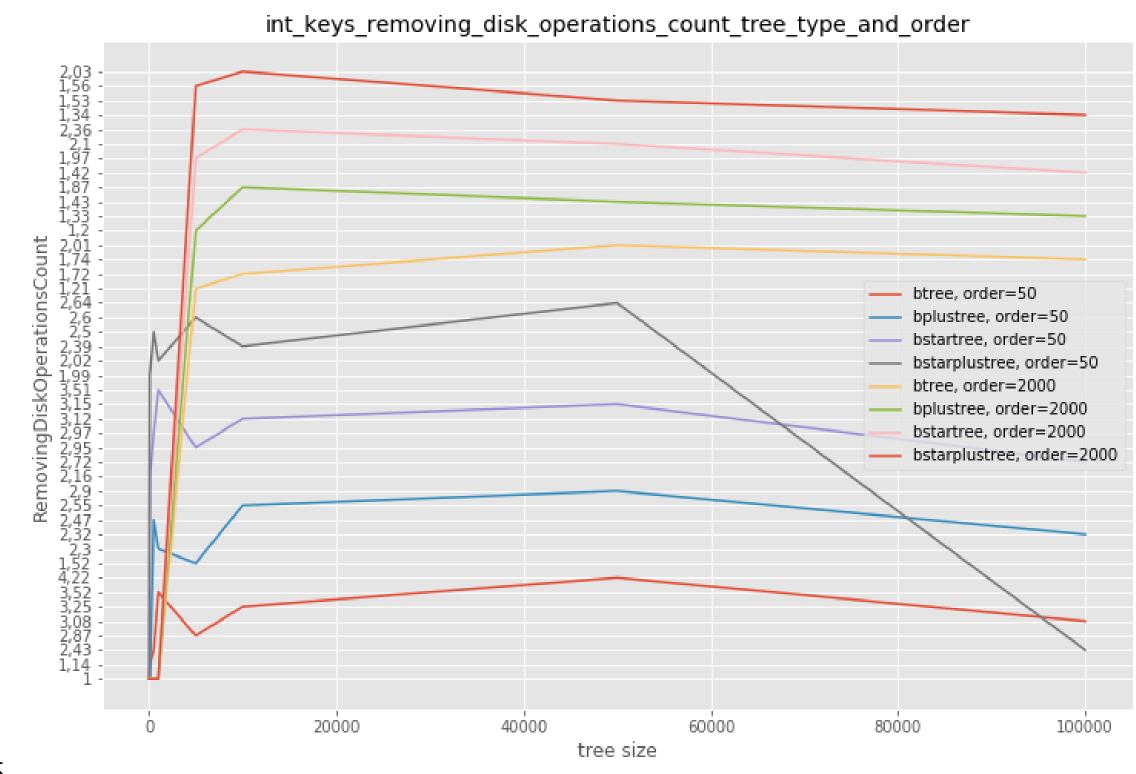
Удаление в дереве (целочисленные ключи) – время





Удаление в дереве (целочисленные ключи) – память и дисковые операции







АЛГОРИТМ ВЫБОРА СТРУКТУРЫ ДАННЫХ ДЛЯ ИНДЕКСАЦИИ

• Использует мультиклассовую линейную классификацию:

$$y_i = w_i^1 rows count + w_i^2 columns count + w_i^3 index size + \beta_i$$
, $i = 1, 2, 3, 4$

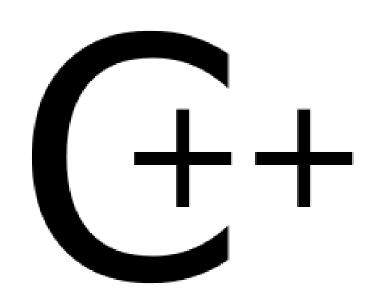
- Дерево, соответствующее *i*-му линейному классификатору выбирается как структура данных для индексирования таблицы тогда и только тогда, когда $y_i = max\{y_1, y_2, y_3, y_4\}$, то есть $i = argmax_i(y_i)$
- Классификаторы обучаются с использованием Python 2 и библиотеки Sci-Kit Learn



МЕТОДЫ И ТЕХНОЛОГИИ



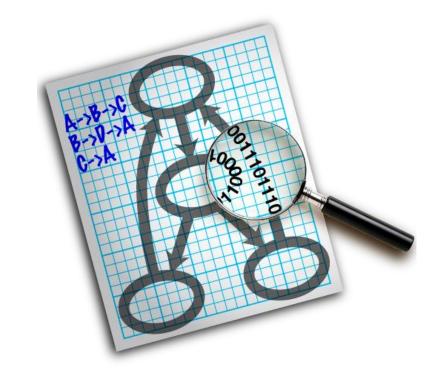














ОЖИДАЕМЫЕ РЕЗУЛЬТАТЫ

- Разработанное расширение для СУБД SQLite, позволяющее использовать в качестве индекса модификации В-дерева: В+-дерево, В*-дерево и В*+-дерево
- Разработанный алгоритм выбора наиболее подходящей структуры данных (В-дерева либо одной из его модификаций) для индексирования таблицы
- Разработанное расширение для SQLite-менеджера для визуализации В-деревьев и их модификаций, а также рассчитанных для них метрик



СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1. B*-tree [Электронный ресурс] // NIST Dictionary of Algorithms and Data Structures. Режим доступа: https://xlinux.nist.gov/dads/HTML/bstartree.html, свободный. (дата обращения: 23.12.2017)
- 2. B-Star Trees [Электронный ресурс] // College of Engineering, Computer Science & Construction Management, Chico, California State University. Режим доступа:

http://www.ecst.csuchico.edu/~mjstapleton/courses/Fall2007 CSCl311/ProgTwo_Bstar.htm, свободный. (дата обращения: 15.01.2018)

- 3. Kerttu Pollari-Malmi. B+-trees // [Электронный ресурс]: Computer Science | University of Helsinki. Режим доступа: https://www.cs.helsinki.fi/u/mluukkai/tirak2010/B-tree.pdf, свободный. (дата обращения: 07.12.2017)
- 4. Run-Time Loadable Extensions [Электронный ресурс] // SQLite. Режим доступа: https://www.sqlite.org/loadext.html, свободный (дата обращения: 04.11.2018)
- 5. Д. Кнут. Искусство программирования. Том 3. 2-е изд. М.: ИД «Вильямс». 2017. 824 с.
- 6. Т. Кормен. Алгоритмы: построение и анализ. 3-е изд. / Т. Кормен, Ч. Лейзерсон, Р. Ривест, К. Штайн. М.: ИД «Вильямс». 2013. 1324 с.



Спасибо за внимание!

amrigin@edu.hse.ru anton19979@yandex.ru anton19979@yandex-team.ru