



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ  
УНИВЕРСИТЕТ

Факультет компьютерных наук  
Департамент программной инженерии

# КОМПОНЕНТ-РАСШИРЕНИЕ РСУБД SQLITE ДЛЯ ИНДЕКСИРОВАНИЯ ДАННЫХ МОДИФИКАЦИЯМИ В-ДЕРЕВЬЕВ

Отчёт по преддипломной практике

Исполнитель: Ригин А.М., студент группы БПИ153

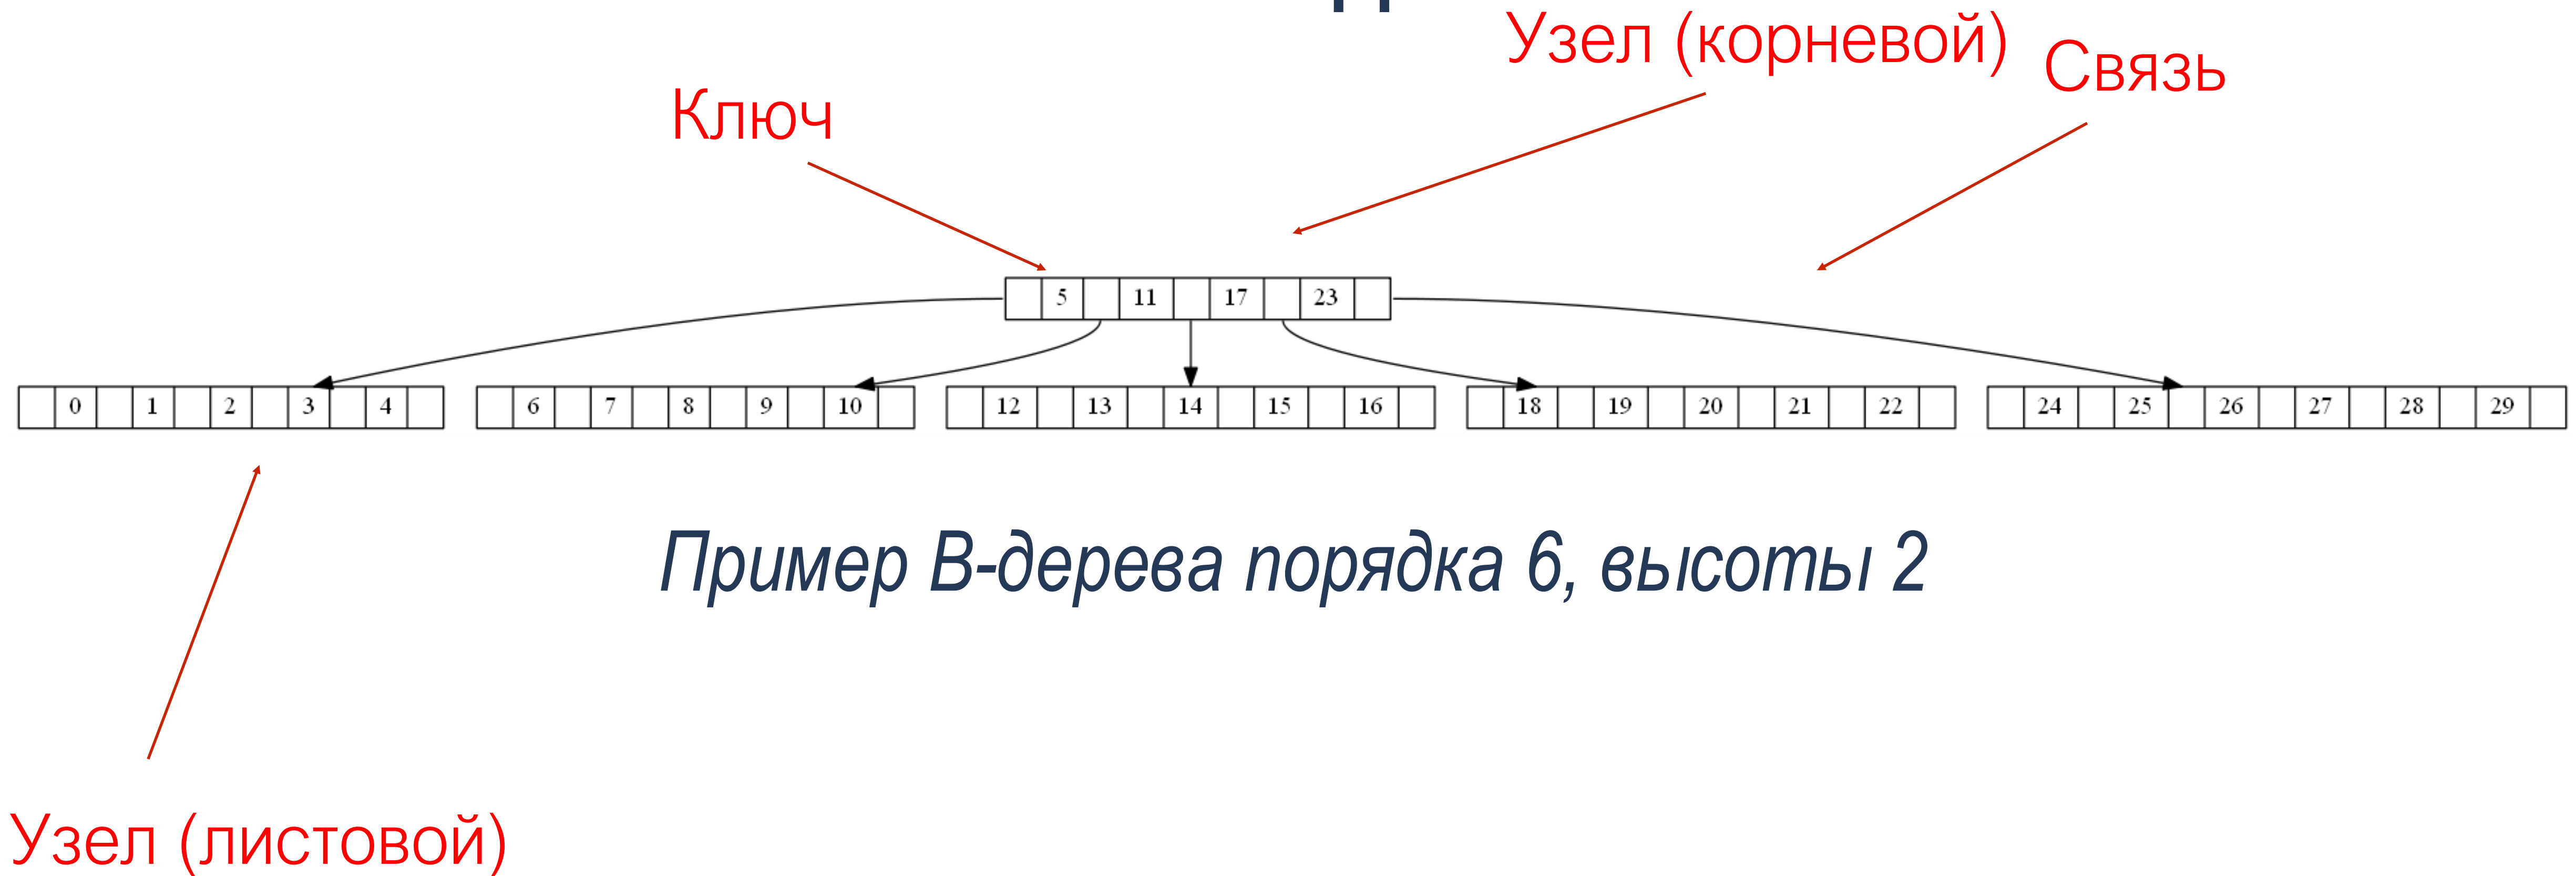
Научный руководитель: Шершаков С.А.,  
ст. преп. ДПИ ФКН, н.с. НУЛ ПОИС ФКН

Москва, 2019

# ПРЕДМЕТНАЯ ОБЛАСТЬ

- Сильно ветвящиеся деревья: В-деревья,  $V^+$ -деревья,  $V^*$ -деревья и  $V^{*+}$ -деревья
- Эмпирическая оценка сложности основных операций и объёма занимаемой памяти
- Индексы в СУБД
- SQLite – встраиваемая реляционная СУБД
- Использование сильно ветвящихся деревьев в качестве индекса в SQLite

# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ



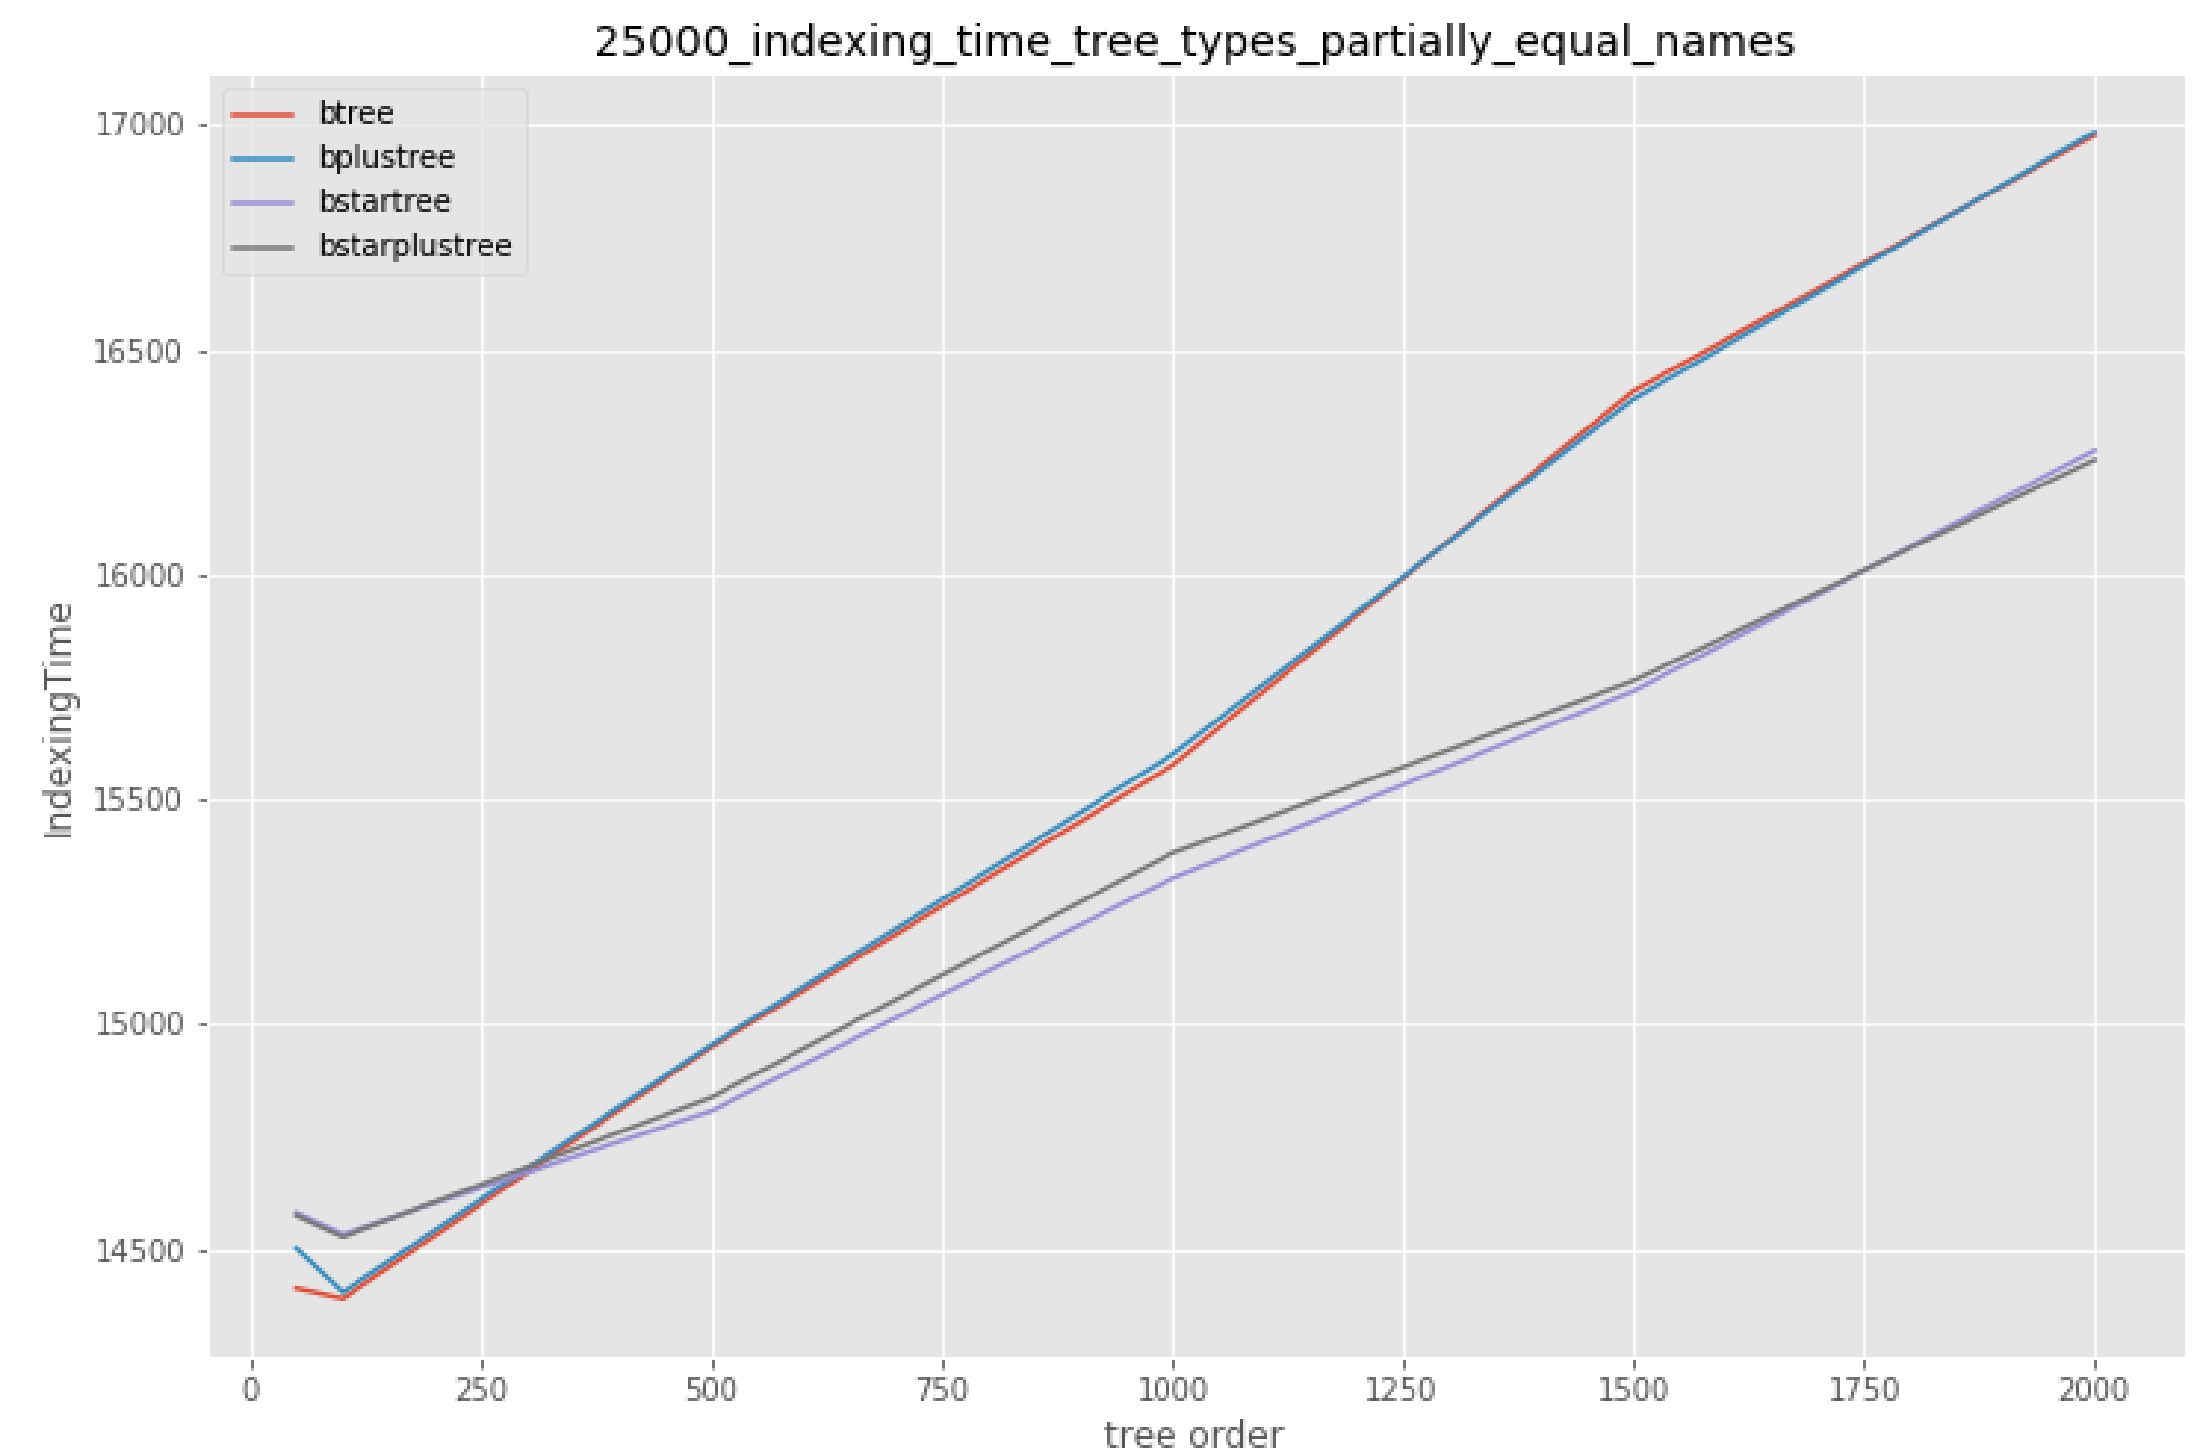

# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- **Сильно ветвящееся дерево** (структура данных) – такое дерево, которое может содержать в одном узле более одного элемента с ключом и более одной связи с дочерними узлами.
  - **В-дерево** – Сильно ветвящееся дерево. В-дерево построено так, что если некоторый нелистовой узел содержит  $k$  ключей, то у данного узла  $k + 1$  потомков, и для любого  $i$ , такого, что  $1 \leq i \leq k + 1$ , верно, что все ключи в  $i$ -м потомке данного узла не меньше, чем  $i$ -й ключ данного узла, и не больше, чем  $i + 1$ -й ключ данного узла [4].
  - **Порядок В-дерева** – такое число  $t$ , что для любого некорневого узла дерева верно неравенство:  $t - 1 \leq k \leq 2t - 1$ , где  $k$  – число ключей в узле. Корневой узел для непустого В-дерева содержит  $1 \leq k \leq 2t - 1$  ключей, для пустого В-дерева – 0 ключей [4].
  - В-дерево является **сбалансированным деревом**, поэтому его высота будет равна  $O(\log_t n)$ , где  $n$  – число ключей в дереве [4].
- [4] Т. Кормен, Ч. Лейзерсон, Р. Ривест, К. Штайн. Алгоритмы: построение и анализ. 3-е изд.


# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- **$B^+$ -дерево** – модификация  $B$ -дерева. В  $B^+$ -дереве настоящие ключи хранятся лишь в листьях дерева, а во внутренних узлах хранятся лишь ключи-маршрутизаторы, необходимые для поиска по дереву. Листья в  $B^+$ -дереве содержат  $t \leq n \leq 2t$  ключей, где  $t$  – порядок дерева, ограничения для внутренних узлов такие же, как и в  $B$ -дереве. [1] [2].
  - **$B^*$ -дерево** – модификация  $B$ -дерева. Каждый узел заполняется не менее, чем на  $2/3$ , а не  $1/2$ . [1].
  - **$B^{*+}$ -дерево** – модификация  $B$ -дерева, разработанная в рамках выполнения курсовой работы за 3 курс [5]. Представляет собой совмещение  $B^+$ -дерева и  $B^*$ -дерева: вершины заполняются не менее, чем на  $2/3$ , как в  $B^*$ -дереве, при этом, как в  $B^+$ -дереве, реальные данные хранятся только в листьях, в остальных вершинах находятся лишь ключи-маршрутизаторы.
- [1] Comer D. The Ubiquitous B-Tree  
[2] Kerttu Pollari-Malmi. B+-trees: <https://www.cs.helsinki.fi/u/mluukkai/tirak2010/B-tree.pdf>  
[5] Ригин А.М. Исследование эффективности сильно ветвящихся деревьев в задаче индексирования структурированных данных

# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ



# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ





# ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

- **СУБД** – система управления базами данных
- **РСУБД** – реляционная СУБД
- **SQLite** – РСУБД с открытым исходным кодом (написана на языке C)
- **Расширение SQLite** – библиотека динамического подключения, расширяющая функционал РСУБД SQLite и предоставляющая новые функции [3]



# АКТУАЛЬНОСТЬ ТЕМЫ И СУЩЕСТВУЮЩИЕ РЕШЕНИЯ

- **Актуальность темы**

- ✓ В настоящее время растут объёмы обрабатываемых данных
- ✓ Необходимо разрабатывать новые эффективные подходы к индексации данных в СУБД
- ✓ СУБД SQLite содержит небольшое число способов индексирования данных – актуально добавление новых

- **Существующие решения**

- ✓ В-дерево является способом индексации по умолчанию в SQLite
- ✓ Существует ряд расширений для SQLite, добавляющих, например, индексирование при помощи R-дерева
- ✓ Расширений с  $B^+$ -деревом,  $B^*$ -деревом и  $B^{*+}$ -деревом не обнаружено


# ЦЕЛЬ И ЗАДАЧИ РАБОТЫ

- **Цель работы**
  - ✓ Разработать расширение для SQLite, позволяющее использовать в качестве индекса в данной СУБД модификации В-дерева:  $B^+$ -дерево,  $B^*$ -дерево и  $B^{*+}$ -дерево
- **Задачи работы**
  - ✓ Реализовать API на C для имеющейся C++-библиотеки алгоритмов над сильно ветвящимися деревьями
  - ✓ Разработать интерфейс подключения данной библиотеки в качестве расширения к SQLite
  - ✓ Разработать алгоритм выбора лучшей структуры данных в качестве индекса
  - ✓ Написать плагин для SQLite Studio для визуализации В-деревьев и их модификаций, а также рассчитанных для них метрик

```

graph LR
    User[Пользователь]
    subgraph "Расширение для SQLite"
        UC1((Создание таблицы))
        UC2((Удаление таблицы))
        UC3((Поиск строки/строк в таблице))
        UC4((Вставка строки/строк в таблицу))
        UC5((Удаление строки/строк из таблицы))
        UC6((Обновление значений ячеек строки/строк в таблице))
        UC7((Переименование таблицы))
        UC8((Сохранение таблицы вместе с базой данных на ПЗУ))
        UC9((Открытие сохранённой вместе с базой данных на ПЗУ таблицы))
        UC10((Перестраивание индексирующей структуры данных на новую))
    end
    User --- UC1
    User --- UC2
    User --- UC3
    User --- UC4
    User --- UC5
    User --- UC6
    User --- UC7
    User --- UC8
    User --- UC9
    UC10 -.->|«extend»| UC3
    UC10 -.->|«extend»| UC4
    UC10 -.->|«extend»| UC5
    UC10 -.->|«extend»| UC6

```




# АЛГОРИТМ ВЫБОРА НАИБОЛЕЕ ПОДХОДЯЩЕЙ ИНДЕКСИРУЮЩЕЙ СТРУКТУРЫ ДАННЫХ

- Выбирает из В-дерева и его модификаций ( $B^+$ -дерева,  $B^*$ -дерева и  $B^{*+}$ -дерева)
- Запускается при каждой операции с таблицей, созданной с использованием разработанного в рамках настоящей работы расширения – поиске строки в таблице, вставке строки в таблицу, обновлении строки в таблице, удалении строки из таблицы
- Производит перестраивание индексирующей структуры данных только на каждой 1000-й операции и только для первых 10000 операций
- Выбор индексирующей структуры данных зависит от соотношений количеств операций разных типов (поиск, вставка, удаление) с деревом



# СТРОЕНИЕ КЛЮЧА В ДЕРЕВЕ




# ТЕХНОЛОГИИ И ИНСТРУМЕНТЫ РЕАЛИЗАЦИИ

THE  
C  
PROGRAMMING  
LANGUAGE



C++



# РЕАЛИЗАЦИЯ

- API на C реализовано в виде динамической библиотеки, с использованием конструкции *extern "C" { ... }*
- Расширение для SQLite регистрирует в СУБД модуль виртуальной таблицы с названием *btrees\_mods*, который «перехватывает» все обращения к виртуальным таблицам, созданным с использованием этого модуля
- Виртуальная таблица – любая таблица, созданная с использованием подобного модуля



# ПРИМЕР ИСПОЛЬЗОВАНИЯ

```
SQLite version 3.26.0 2018-12-01 12:34:55
Enter ".help" for usage hints.
Connected to a transient in-memory database.
Use ".open FILENAME" to reopen on a persistent database.
sqlite> .load ./btrees_mods
sqlite> CREATE VIRTUAL TABLE btt USING btrees_mods(id INTEGER PRIMARY KEY, a INTEGER, b TEXT);
sqlite> INSERT INTO btt VALUES (4, 2, "ABC123");
sqlite> INSERT INTO btt VALUES (7, 3, "def");
sqlite> SELECT * FROM btt WHERE id = 4;
4|2|ABC123
sqlite> SELECT * FROM btt WHERE id = 7;
7|3|def
sqlite> SELECT * FROM btt WHERE id = 4 OR id = 7;
4|2|ABC123
7|3|def
sqlite> .tables
btrees_mods_idxinfo  btt                                btt_real
sqlite> SELECT * FROM btt_real;
4|2|ABC123
7|3|def
sqlite> SELECT * FROM btrees_mods_idxinfo;
btt|1|0|id|INTEGER|4|tree_9772907171555888658.btree
sqlite> DROP TABLE btt;
sqlite> .tables
btrees_mods_idxinfo
sqlite> SELECT * FROM btrees_mods_idxinfo;
sqlite>
```

# АПРОБАЦИЯ РАБОТЫ

- Работа представлена на Студенческой конференции ФКН CoCoS'2019 в исследовательском треке
- Работа подана на Международную конференцию SYRCoSE 2019

# ОСНОВНЫЕ РЕЗУЛЬТАТЫ ПРАКТИКИ

- **Выполнено**
  - ✓ Реализовано API на C для имеющейся C++-библиотеки алгоритмов над сильно ветвящимися деревьями
  - ✓ Разработано расширение для SQLite
  - ✓ Разработан и реализован алгоритм выбора лучшей структуры данных в качестве индекса
  - ✓ Написан драфт текста ВКР и драфт ТЗ
- **Осталось выполнить**
  - ✓ Написать расширение для SQLite Studio для визуализации B-деревьев и их модификаций, а также рассчитанных для них метрик (до 12.05.2019 г.)
  - ✓ Написать окончательный текст ВКР, ТЗ, ПиМИ, РО, ТП
- **Приблизительный процент выполнения: ~90 % по программному продукту, ~50 % по документации, итого ~83 %**

## ОЖИДАЕМЫЕ РЕЗУЛЬТАТЫ ВКР

- Разработанное расширение для СУБД SQLite, позволяющее использовать в качестве индекса модификации В-дерева:  $B^+$ -дерево,  $B^*$ -дерево и  $B^{*+}$ -дерево
- Разработанное расширение для SQLite Studio для визуализации В-деревьев и их модификаций, а также рассчитанных для них метрик
- Направления дальнейших разработок:
  - $<$ ,  $<=$ ,  $>$ ,  $>=$  при поиске строк по первичному ключу
  - Поддержка транзакционности
  - Доработки C++-библиотеки сильно ветвящихся деревьев, для снижения сложности операций

# СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Comer D. The Ubiquitous B-Tree // ACM Computing Surveys. – 1979. – June (vol. 11, no. 2). – P. 121 – 137.
2. Pollari-Malmi K. B+-trees // [Электронный ресурс]: Computer Science | University of Helsinki. Режим доступа:  
<https://www.cs.helsinki.fi/u/mluukkai/tirak2010/B-tree.pdf>, свободный. (дата обращения: 07.12.2017).
3. Run-Time Loadable Extensions // [Электронный ресурс]: SQLite. Режим доступа:  
<https://www.sqlite.org/loadext.html>, свободный (дата обращения: 04.11.2018)
4. Кормен Т. Алгоритмы: построение и анализ. 3-е изд. / Т. Кормен, Ч. Лейзерсон, Р. Ривест, К. Штайн. — М.: ИД «Вильямс». — 2013. — 1324 с.
5. Ригин А.М. Исследование эффективности сильно ветвящихся деревьев в задаче индексирования структурированных данных : Курсовая работа / Ригин Антон Михайлович; НИУ ВШЭ. – М., 2018. – 37 с.



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ  
УНИВЕРСИТЕТ

Спасибо за внимание!

[amrigin@edu.hse.ru](mailto:amrigin@edu.hse.ru)

[anton19979@yandex.ru](mailto:anton19979@yandex.ru)

[anton19979@yandex-team.ru](mailto:anton19979@yandex-team.ru)